



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ

ΠΛΗΡΟΦΟΡΙΚΗΣ

Σύγχρονες προσεγγίσεις στη διαχείριση και ανάλυση δημόσιων βιολογικών αλληλουχιών

Θεωρητική Εργασία στη Βιοπληροφορική

Διδάσκων: Χρήστος Μακρής

Μέλη Ομάδας

Ονοματεπώνυμο	Αριθμός Μητρώου	Έτος Σπουδών
Ζαφειρία Τσάλα	1084963	5ο
Καλανδράκης Βασίλειος 2	1084577	7ο

Πάτρα, Σεπτέμβριος 2026

Περιεχόμενα

1	Εισαγωγή	3
1.1	Ιστορική αναδρομή	3
1.2	Θεμελιώδεις έννοιες και εφαρμογές	4
1.3	Ο κοινός άξονας και η δομή της εργασίας	5
2	Αποθήκευση και διάθεση δεδομένων: το GenBank	6
2.1	Το GenBank και το οικοσύστημα INSDC	6
2.2	Τρόποι πρόσβασης στα δεδομένα	8
2.3	Υποβολή δεδομένων και διασφάλιση ποιότητας	9
2.4	Πρόσφατες εξελίξεις και στήριξη της κοινότητας	10
3	Αναζήτηση σε κλίμακα petabase: το MetaGraph	11
3.1	Το πρόβλημα της αναζήτησης πλήρους κειμένου	11
3.2	Ευρετηρίαση με annotated de Bruijn graphs	12
3.3	Οι τεχνικές συμπίεσης	13
3.4	Αποτελέσματα: κλίμακα, κόστος και ακρίβεια	14
3.5	Εφαρμογές και περιορισμοί	15
4	Αξιοποίηση δεδομένων: εξόρυξη και εκτός στόχου αναγνώσεις	16
4.1	Η ιδέα των "εκτός στόχου αναγνώσεων"	16
4.2	Μεθοδολογία: από την εξόρυξη στην ανάλυση	17
4.3	Τα τρία μεγάλα οφέλη	18
4.4	Προκλήσεις και καλές πρακτικές	20
5	Ανάλυση αλληλουχιών με τεχνητή νοημοσύνη	21
5.1	Το χάσμα μεταξύ βιολογίας και τεχνητής νοημοσύνης	21
5.2	Οι εργασίες και οι βιολογικοί στόχοι	22
5.3	Αναπαράσταση αλληλουχιών	23
5.4	Γλωσσικά μοντέλα και Transformers	24
5.5	Predictors, αξιολόγηση και τάσεις	24
5.6	Περιορισμοί και προβλήματα συγκριτικής αξιολόγησης	25

6	Πρόσθετο υλικό & μελλοντικές εφαρμογές	26
6.1	Αξιοποίηση εκτός στόχου αναγνώσεων σε νέα πεδία	26
6.2	Η επόμενη γενιά αναζήτησης σε αποθετήρια	27
6.3	Η υποδομή δεδομένων ως θεμέλιο	27
6.4	Σύγκλιση τεχνητής νοημοσύνης και αλληλούχισης	28
7	Επίλογος	30

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορική αναδρομή

Η δυνατότητα ανάγνωσης της αλληλουχίας του DNA έχει ιστορία λίγων μόλις δεκαετιών. Αφετηρία της αποτελεί η αποκρυπτογράφηση της τρισδιάστατης δομής του DNA το 1953 όπου οι Watson και Crick περιέγραψαν τη δομή της διπλής έλικας, αξιοποιώντας τα κρυσταλλογραφικά δεδομένα των Franklin και Wilkins [20, 16]. Η ανακάλυψη αυτή, που σφράγισε την ιστορία της μοριακής βιολογίας και αναγνωρίζεται ως θεμελιώδης έως σήμερα [21, 18], έδωσε το εννοιολογικό πλαίσιο για την κατανόηση του γενετικού υλικού. Η ανάγνωση όμως της αλληλουχίας δεν ακολούθησε αμέσως.

Οι πρώτες προσπάθειες εστίασαν στο RNA, το οποίο ήταν ευκολότερος στόχος καθώς είναι μονόκλωνο και πιο "κοντό" από το DNA. Το 1965 ο Holley παρήγαγε την πρώτη πλήρη αλληλουχία νουκλεϊκού οξέος, εκείνη του tRNA αλανίνης από τον ζυμομύκητα "*S. cerevisiae*", ενώ το εργαστήριο του Fiers πραγματοποίησε ανάλυση της αλληλουχίας ,το 1972, στο πρώτο πλήρες γονίδιο που κωδικοποιεί πρωτεΐνη, και το 1976 ολόκληρο το γονιδίωμα του "φάγου MS2".

Η πρώτη γενιά μεθόδων ανάγνωσης του DNA διαμορφώθηκε στα μέσα της δεκαετίας του 1970. Καθοριστική ήταν μια βελτίωση στον τρόπο διαχωρισμού των μορίων: η χρήση της ηλεκτροφόρησης σε πηκτή, που πρόσφερε πολύ μεγαλύτερη ακρίβεια από τις προηγούμενες μεθόδους.Κεντρική μορφή αυτής της περιόδου υπήρξε ο Frederick Sanger. Μαζί με τον Coulson ανέπτυξε το 1975 μια πρώτη μέθοδο ανάγνωσης του DNA, με την οποία διαβάστηκε το πρώτο ολόκληρο γονιδίωμα. Παράλληλα, οι Maxam και Gilbert πρότειναν μια εναλλακτική, χημική προσέγγιση, που ήταν η πρώτη που υιοθετήθηκε ευρέως. Το πραγματικό ορόσημο, όμως, ήρθε το 1977, όταν ο Sanger παρουσίασε τη μέθοδο τερματισμού αλυσίδας τη λεγόμενη "Sanger sequencing". Χάρη στην ακρίβεια και την απλότητά της, η μέθοδος αυτή κυριάρχησε για δεκαετίες και του χάρισε αναγνώριση παγκοσμίως. Στη συνέχεια, μέσα στη δεκαετία του 1980, σταδιακές βελτιώσεις οδήγησαν στα πρώτα αυτοματοποιημένα, εμπορικά μηχανήματα, τα οποία αργότερα αποδείχθηκαν καθοριστικά για

την εξέλιξη της επιστήμης [5].

Η δεύτερη γενιά έφερε μια ριζική αλλαγή κλίμακας. Συγκεκριμένα ντί να διαβάζεται ένα κομμάτι DNA τη φορά, γίνεται πλέον δυνατή η ταυτόχρονη ανάγνωση εκατομμυρίων κομματιών. Πρώτη επιτυχημένη εμπορική πλατφόρμα ήταν η τεχνολογία της εταιρείας 454, αλλά εκείνη που επικράτησε σχεδόν απόλυτα ήταν η μέθοδος της "Illumina". Άλλες πλατφόρμες, όπως το "SOLiD και το Ion Torrent", πρόσφεραν εναλλακτικές λύσεις. Η πρόοδος υπήρξε εκρηκτική, μεταξύ 2004 και 2010, οι δυνατότητες ανάγνωσης και ανάλυσης αλληλουχιών DNA διπλασιάζονταν κάθε πέντε μήνες ρυθμός πολύ ταχύτερος ακόμη και από την εξέλιξη των υπολογιστών (τον νόμο του Moore).

Η τρίτη γενιά, την οποία ακόμα διανύουμε, χαρακτηρίζεται από την ανάγνωση μεμονωμένων μορίων DNA, χωρίς να χρειάζεται πρώτα να πολλαπλασιαστούν. Οι νέες τεχνολογίες, επιτρέπουν την ανάγνωση πολύ μεγάλων τμημάτων. Μάλιστα, η μικρή, φορητή συσκευή "MinION" κατέστησε εφικτή την επεξεργασία γονιδιωμάτων ακόμη και "στο πεδίο". Χαρακτηριστική αποτελεί η περίπτωση όπου χρησιμοποιήθηκε για την ανίχνευση του ιού Έμπολα στη Γουινέα, μόλις δύο ημέρες μετά τη λήψη των δειγμάτων [5].

Η συνολική πορεία, από τον επίπονο προσδιορισμό δεκάδων νουκλεοτιδίων RNA, στη μαζική παραγωγή εκατοντάδων εκατομμυρίων, συνοψίζει τη μετάβαση της βιολογίας σε μια εποχή όπου η ανάλυση των δεδομένων έγινε εξίσου απαιτητική με την παραγωγή τους. Καθώς οι ερευνητές πέρασαν, όπως εύστοχα έχει διατυπωθεί, "από το εργαστήριο στον υπολογιστή", τα δημόσια αποθετήρια αλληλουχιών άρχισαν να διογκώνονται διαρκώς και ακριβώς αυτή η διόγκωση ορίζει το αντικείμενο της παρούσας εργασίας.

1.2 Θεμελιώδεις έννοιες και εφαρμογές

Πριν προχωρήσουμε, είναι χρήσιμο να αποσαφηνιστούν ορισμένες έννοιες που επανέρχονται σε όλα τα κεφάλαια. Μια αλληλουχία (sequence) είναι μια συμβολοσειρά από νουκλεοτίδια (A, C, G, T για το DNA) ή αμινοξέα για τις πρωτεΐνες. Τα ακατέργαστα δεδομένα μιας αλληλούχισης αποτελούνται από πλήθος σύντομων αναγνώσεων (reads), οι οποίες στη συνέχεια συναρμολογούνται σε μεγαλύτερες αλληλουχίες ή γονιδιώματα. Κεντρικό ρόλο σε τρία από τα τέσσερα έργα που εξετάζονται αποτελεί η έννοια του k -mer (πρόκειται για κάθε υποακολουθία σταθερού μήκους k που προκύπτει από μια αλληλουχία). Τα k -mers λειτουργούν άλλοτε ως στοιχειώδη μονάδα ευρετηρίασης και αναζήτησης και άλλοτε ως "λέξεις" μιας γλώσσας που τροφοδοτεί μοντέλα τεχνητής νοημοσύνης.

Εξίσου κρίσιμα με τις ίδιες τις αλληλουχίες είναι τα μεταδεδομένα (metadata) που τις συνοδεύουν. Ως μεταδεδομένα θεωρούνται ο οργανισμός προέλευσης, ο ξενιστής (οργανισμός που φέρει άλλους παρασιτικούς οργανισμούς), η γεωγραφική τοποθεσία και η ημερομηνία δειγματοληψίας. Η ποιότητα και η πληρότητα αυτών των μεταδεδομένων καθορίζει σε μεγάλο βαθμό την επαναχρησιμοποίηση των δεδομένων, ένα ζήτημα που, όπως θα δούμε, αποτελεί έναν από τους σοβαρότερους περιορισμούς της εξόρυξης δεδομένων.

Οι φορείς και οι οργανώσεις που αναφέρονται στην παρούσα εργασία τηρούν τις αρχές "FAIR" όπου τα δεδομένα οφείλουν να είναι εντοπίσιμα (Findable), προσβάσιμα (Accessible), διαλειτουργικά (Interoperable) και επαναχρησιμοποιήσιμα (Reusable). Οι αρχές αυτές δεν είναι απλώς ένα σύνθημα, μεταφράζονται σε συγκεκριμένες τεχνικές επιλογές, όπως η χρήση σταθερών αναγνωριστικών, η τυποποίηση των μεταδεδομένων και η καθημερινή ανταλλαγή δεδομένων.

1.3 Ο κοινός άξονας και η δομή της εργασίας

Η παρούσα εργασία συνθέτει τέσσερις πρόσφατες δημοσιεύσεις, καθεμία εκ των οποίων φωτίζει μια διαφορετική πτυχή του ίδιου, ενιαίου προβλήματος. Συγκεκριμένα το πεδίο ενασχόλησης περιστρέφεται γύρω από το πώς διαχειριζόμαστε, αναζητούμε και αξιοποιούμε τον τεράστιο όγκο δημόσιων βιολογικών αλληλουχιών. Παρότι τα τέσσερα έργα προέρχονται από διαφορετικές ερευνητικές ομάδες και δημοσιεύτηκαν σε διαφορετικά περιοδικά, μοιράζονται έναν κοινό θεματικό πυρήνα, δηλαδή τις δημόσιες βάσεις βιολογικών δεδομένων και εξετάζουν κοινές θεμελιώδεις έννοιες του κλάδου της Βιοπληροφορικής.

Κεφάλαιο 2

Αποθήκευση και διάθεση δεδομένων: το GenBank

Το πρώτο σκέλος του κύκλου ζωής των δεδομένων είναι η ίδια η υποδομή που τα συλλέγει, τα οργανώνει και τα διαθέτει. Το κεφάλαιο αυτό βασίζεται στην ετήσια αναφορά του GenBank για το 2025, η οποία αποτελεί μια περιγραφή της τρέχουσας κατάστασης, του περιεχομένου και των πρόσφατων εξελίξεων της βάσης.

2.1 Το GenBank και το οικοσύστημα INSDC

Το GenBank είναι ένα δημόσιο αποθετήριο νουκλεοτιδικών αλληλουχιών, το οποίο συνοδεύεται από βιβλιογραφικές και βιολογικές επισημειώσεις (annotations). Σύμφωνα με την αναφορά του 2025, το περιεχόμενό του προσεγγίζει τα 34 τρισεκατομμύρια ζεύγη βάσεων, προερχόμενα από πάνω από 4,7 δισεκατομμύρια αλληλουχίες που καλύπτουν περισσότερα από 581.000 επίσημα περιγεγραμμένα είδη. Τα δεδομένα του GenBank, εκτός του ότι ενημερώνονται τακτικά, είναι διαθέσιμα παγκοσμίως. Μάλιστα γίνεται και ανταλλάγή δεδομένων με σημαντικούς φορείς όπως το "European Nucleotide Archive" και "DNA Data Bank of Japan" καθώς και οι τρεις οργανισμοί βρίσκονται κάτω από την ομπρέλα του INSDC (International Nucleotide Sequence Database Collaboration)[3].

Τα δεδομένα του GenBank κατανέμονται σε 21 τμήματα (divisions), με κριτήριο είτε την ταξινόμηση του πηγαίου υλικού είτε τη στρατηγική αλληλουχίας που χρησιμοποιήθηκε. Ενδεικτικά, υπάρχουν τμήματα τα οποία εμπεριέχουν δεδομένα ολόκληρων φυσικών γονιδιωμάτων, τεχνητών γονιδιομάτων (τα οποία προκύπτουν από την διαδικασία της μεταγραφής) ή ακόμα και δεδομένα που προέρχονται από ολόκληρους γονιδιακούς τόπους, τα οποία χρησιμεύουν σε περαιτέρω μελέτες. Η συλλογή όλων αυτών των δεδομένων βέβαια καθιστά το GenBank, ίσως το πιο χρήσιμο "εργαλείο" στην φαρέτρα του NCBI (National Center for Biotechnology Information) διότι δεν είναι λίγα τα προϊόντα και οι έρευνες που έγιναν πράξη λόγω αυτού. Λόγου χάρη η συλλογή αναφοράς "RefSeq", η βάση "NCBI

Gene”, οι βάσεις του εργαλείου ”BLAST” και το ”NCBI Virus”.

Πίνακας 2.1: Ετήσια ανάπτυξη του GenBank κατά την περίοδο 2009-2024

Έτος	Εγγραφές αλληλουχιών (δισεκατομμύρια)	Ζεύγη βάσεων (τρισεκατομμύρια)
2009	0,15	0,3
2010	0,19	0,4
2011	0,22	0,5
2012	0,25	0,6
2013	0,31	0,8
2014	0,38	1,0
2015	0,59	1,6
2016	0,67	2,1
2017	0,89	2,7
2018	1,15	3,7
2019	1,64	6,3
2020	2,10	9,8
2021	2,48	15,3
2022	2,93	19,5
2023	3,69	25,0
2024	4,75	34,0

Χαρακτηριστικά, η ίδια η δυναμική ανάπτυξης αποτυπώνεται στην αύξηση κατά περίπου 77.000 ειδών, ποσοστό της τάξεως του 15%, μέσα σε ένα μόλις έτος.

Η κεντρική θέση του GenBank στο οικοσύστημα του NCBI αξίζει να αναλυθεί περαιτέρω, καθώς μας δείχνει γιατί η ποιότητα μιας βάσης δεδομένων αφήνει εμφανές αποτύπωμα σε δεκάδες παράγωγα προϊόντα. Χαρακτηριστικά όπως αναφέρεται και στο άρθρο, οι εννοιολογικές μεταφράσεις των κωδικοποιουσών περιοχών των αλληλουχιών του GenBank τροφοδοτούν τον πόρο Protein του NCBI. Εν συνεχεία οι ίδιες αυτές πρωτεϊνικές αλληλουχίες με την σειρά τους στηρίζουν τη ”Conserved Domain Database”, ένα βασικό συστατικό των διεργασιών που προσθέτουν λειτουργική επισημείωση σε γονιδιώματα. Παράλληλα, το GenBank λειτουργεί ως η κύρια πηγή πρωτογενών δεδομένων από την οποία παράγονται η συλλογή ”RefSeq”, οι εγγραφές της βάσης ”NCBI Gene”, ενώ παράλληλα αποτελεί και τη μεγαλύτερη πηγή για τις βάσεις του ”BLAST”. Η αλυσίδα αυτή εξηγεί γιατί το GenBank επενδύει τόσο στη διασφάλιση ποιότητας, κάθε σφάλμα ή δυσλειτουργία θα διαδιδόταν σε ολόκληρο το οικοσύστημα.

Επιπρόσθετα, όπως έχει γίνει ήδη αντιληπτό, το GenBank δεν αναλώνεται σε στείρα αποθήκευση δεδομένων. Βοηθάει ενεργά την επιστημονική -και μη - κοινότητα να δημιουργούν συνεργατικά εγγραφές Third Party Annotation (TPA), οι οποίες αναπαριστούν στην πράξη προσπάθειες συναρμολόγησης ή επισημείωσης δεδομένων που κατατέθηκαν από διάφορους χρήστες. Επιπλέον, ο σύγχρονος πόρος NCBI Datasets προσφέρει μια πλήρως ανασχεδιασμένη προβολή των κόμβων του ταξινομημένου δέντρου του GenBank,

δίνοντας στους χρήστες ένα εύκολο τρόπο να περιηγηθούν και να κατεβάσουν γονιδιώματα, νουκλεοτιδικές και πρωτεϊνικές αλληλουχίες, δεδομένα SRA και εγγραφές BioProject για οποιονδήποτε κόμβο. Σημαντικό επίσης να αναφερθεί είναι ότι σε συνεργασία με το INSDC, το NCBI με κύριο εργαλείο το GenBank ενθαρρύνει τους χρήστες να αναφέρουν χωρο-χρονικά μεταδεδομένα, ώστε τα δεδομένα να αντανακλούν σωστά τη γεωγραφική κατανομή της δειγματοληψίας.

Η αξία αυτής της υποδομής στην πράξη γίνεται ορατή από το παράδειγμα του COVID-19. Πριν το 2020, το GenBank περιείχε ήδη μερικά εκατομμύρια ιικά γονιδιώματα, εκ των οποίων ελάχιστα ανήκαν σε κορονοϊούς. Παρ' όλα αυτά, η προϋπάρχουσα υποδομή και το κοινό σύστημα ευρετηρίασης επέτρεψαν στο NCBI να δημοσιεύσει ταχύτατα έναν ειδικό πόρο για τους κορονοϊούς, στηρίζοντας την απόκριση της δημόσιας υγείας. Μέσα σε λιγότερο από δύο χρόνια, το πλήθος των ιικών γονιδιωμάτων υπερδιπλασιάστηκε, με τους κορονοϊούς να αποτελούν πλέον περίπου το ένα τρίτο της ιικής συλλογής.

2.2 Τρόποι πρόσβασης στα δεδομένα

Στη συνέχεια η εν λόγω αναφορά περιγράφει τρία επίπεδα πρόσβασης, καθένα προσαρμοσμένο σε διαφορετικές ανάγκες. Το πιο άμεσο είναι το διαδικτυακό περιβάλλον, πιο συγκεκριμένα μέσω της υπηρεσίας "Nucleotide" του "NCBI" ο κάθε χρήστης δύναται να αναζητήσει δεδομένα με βάσει αριθμούς πρόσβασης (accession numbers), τον τίτλο της κάθε καταχώρησης, το όνομα του φορέα ή του ατόμου που έκανε την καταχώρηση κ.α. Συμπληρωματικά, εργαλεία όπως το "Blast" προσφέρουν μια εναλλακτική λογική αναζήτησης, βασισμένη όχι σε μεταδεδομένα αλλά στα ίδια τα δεδομένα της αλληλουχίας, πράγμα που είναι σημαντικό για την επικύρωση επισημειώσεων. Μιας και αναφέρθηκε το "Blast" σαν τρόπος αναζήτησης, αξίζει να σημειωθεί ότι, καθώς μεγάλωσε η βάση δεδομένων του GenBank, μεγάλωσαν και εξελίχθηκαν οι βάσεις του Blast για μεγαλύτερη απόδοση και στοχευμένα αποτελέσματα αναζήτησης.

Το δεύτερο επίπεδο αφορά τη "προγραμματιστική πρόσβαση". Οι "Entrez Programming Utilities" λειτουργούν με αυτοματοποιημένη υποβολή ερωτημάτων και ανάκτηση εγγραφών σε διάφορες μορφές, όπως το παραδοσιακό "flat file" του GenBank, "XML" και "Fasta". Μια συνολική επισκόπηση των εργαλείων, των βάσεων και των μορφότυπων που χρησιμοποιούνται σε τέτοιες ροές εργασίας δίνεται στη σχετική βιβλιογραφία [4]. Παρέχεται επίσης "API" για το "Blast", ενώ οι χρήστες μπορούν να κατεβάσουν λογισμικό και βάσεις του "Blast" για τοπική εκτέλεση χωρίς σύνδεση στους διακομιστές του "NCBI". Τέλος ο τρίτος τρόπος πρόσβασης στα δεδομένα του GenBank γίνεται μέσω "FTP", όπου το "NCBI", παρέχει πλήρεις εκδόσεις των εγγραφών του GenBank τόσο σε μορφή "flat file" όσο και σε δομημένη μορφή "ASN1", συνοδευόμενες πάντα από ημερήσια αρχεία ενημέρωσης με τις νέες και τροποποιημένες εγγραφές. Το μέγεθος αυτών των εκδόσεων μαρτυρά την μεγάλη κλίμακα της βάσης ενώ σύμφωνα με το άρθρο [13] μια πρόσφατη πλήρης έκδοση αποτελούνταν από

αρκετές χιλιάδες αρχεία και καταλάμβανε αρκετά "terabytes" σε ασυμπίεστη μορφή, ποσότητα που καθιστά την τοπική λήψη ολόκληρης της βάσης πρακτική μόνο για εξειδικευμένες εφαρμογές. Ακριβώς αυτή η δυσκολία της εξαντλητικής τοπικής πρόσβασης είναι που κινητοποιεί την ανάγκη για αποδοτικότερες μεθόδους αναζήτησης, τις οποίες πραγματεύεται το επόμενο κεφάλαιο.

Ένα πρακτικό αλλά ουσιώδες σημείο που αξίζει να σημειωθεί αφορά τον ορθό τρόπο παραπομπής σε μια εγγραφή. Ο ενδεδειγμένος τρόπος είναι η χρήση του πλήρους αναγνωριστικού "accession version" (για παράδειγμα, AF123456.2), καθώς μόνο έτσι αναχτάται η ακριβής έκδοση της εγγραφής που αναφέρει ο συγγραφέας. Η αναζήτηση με το σκέτο "accession" επιστρέφει πάντα την τρέχουσα έκδοση, η οποία όμως ενδέχεται να έχει μεταβληθεί.

2.3 Υποβολή δεδομένων και διασφάλιση ποιότητας

Πέρα από την πρόσβαση στα δεδομένα της βάσης, η αναφορά δίνει έμφαση στη διαδικασία κατάθεσης-υποβολής δεδομένων, η οποία μεταβαίνει σταδιακά σε σύγχρονη πύλη υποβολής (submission portal), αντικαθιστώντας το παλαιότερο μοντέλο "Bankit". Μια από τις πρόσφατες βελτιώσεις είναι η δυνατότητα προσθήκης χαρακτηριστικών όπως περιοχές κωδικοποίησης (CDS) και επισημειώσεις πρωτεϊνών μέσω της αποστολής πινάκων χαρακτηριστικών (feature tables) για ευκαρυωτικές αλληλουχίες αγγελιαφόρου RNA.

Προκειμένου οι υποβολές να εντάσσονται σε θεσμικό έλεγχο του εν λόγω προγράμματος "FAIR" δημιουργήθηκαν οι εξής πόροι: "BioProject" και "BioSample". Το BioProject συνδέει εγγραφές που προέρχονται από την ίδια επιστημονική έρευνα αλλά βρίσκονται σε διαφορετικά αποθετήρια του NCBI, καθώς και με σχετική βιβλιογραφία και πηγές χρηματοδότησης, παρέχοντας ένα ενιαίο σημείο πρόσβασης. Το BioSample, από την άλλη, επιβάλλει συνέπεια στα μεταδεδομένα και ακρίβεια κατά την διαδικασία ταξινόμησης, ώστε ο τελικός χρήστης να μπορεί να ανακτήσει ουσιαστική περιγραφική πληροφορία για την προέλευση των δεδομένων. Η σημασία αυτού είναι ιδιαίτερα μεγάλη στη βιοϊατρική έρευνα και τη δημόσια υγεία, όπου η κατανόηση της προέλευσης των δεδομένων είναι προϋπόθεση για την εξαγωγή αξιόπιστων συμπερασμάτων.

Ένα ζήτημα που θα αναλυθεί με περισσότερη έμφαση στο τέταρτο κεφάλαιο της παρούσας εργασίας είναι η μόλυνση των δεδομένων (contamination). Επομένως θα πρέπει, όχι μόνο να αντιμετωπισθεί αυτό το πρόβλημα αλλά να μην κοστίζει και σε χρόνο. Ένας από τους αποτελεσματικότερους τρόπους επιτάχυνσης της δημοσίευσης δεδομένων είναι η διασφάλιση ότι αυτά είναι απαλλαγμένα από αλληλουχίες που δεν προέρχονται από τον βιολογικό στόχο. Για τον σκοπό αυτό, το NCBI παρέχει το εργαλείο "Foreign Contamination Screening" (FCS), το οποίο ανιχνεύει τόσο "adaptors" και "vectors" όσο και "μολυν-

σμένες αλληλουχίες”, επιτρέποντας στους χρήστες οι οποίοι πραγματοποιούν υποβολή, να προελέγχουν τα δεδομένα τους. Ιδιαίτερη μνεία γίνεται επίσης στα μεταγονιδιώματα (metagenomes), όπου πραγματοποιείται η συμπερίληψη των ακατέργαστων αναγνώσεων.

2.4 Πρόσφατες εξελίξεις και στήριξη της κοινότητας

Στις σημαντικότερες πρόσφατες εξελίξεις συγκαταλέγεται η επιταχυμένη δημοσίευση αλληλουχιών γρίπης, κατά το πρότυπο που ακολουθήθηκε κατά την περίοδο της πανδημίας Covid. Την δεδομένη περίοδο θεωρήθηκε κρίσιμο να αναβαθμιστούν οι διαδικασίες ελέγχου των δεδομένων που υποβάλλονταν. Πιο συγκεκριμένα οι νέες αναβαθμίσεις περιλαμβάνουν σειρά ποιοτικών ελέγχων, λόγου χάρη “trimming” και αφαίρεση αλληλουχιών που δεν πληρούν ελάχιστα κατώφλια μήκους και ποιότητας. Μετά τον έλεγχο, χαρακτηριστικά όπως οι κωδικοποιημένες περιοχές και τα γονίδια προστίθενται αυτόματα μέσω του εργαλείου FLAN (FLu ANnotation). Σε περίπτωση που εντοπισθούν τυχόν προβλήματα με τις επισημειώσεις ή τις αλληλουχίες γίνεται ενημέρωση του χρήστη που υπέβαλε τα δεδομένα διότι είναι σημαντικό οι εγγραφές που περνούν όλους τους ελέγχους να πληρούν πρότυπα ποιότητας, να φέρουν τυποποιημένες επισημειώσεις και να είναι πιο επαναχρησιμοποιήσιμες. Η σημασία αυτής της αυτοματοποίησης είναι διττή, αφενός επιταχύνει δραματικά τη διάθεση κρίσιμων για τη δημόσια υγεία δεδομένων, αφετέρου εξασφαλίζει ότι η ταχύτητα δεν επιτυγχάνεται εις βάρος της τυποποίησης ,μια ισορροπία που αποτελεί διαρκές ζητούμενο σε όλα τα αποθετήρια.

Η συγκεκριμένη δημοσίευση καταγράφει επίσης αλλαγές που θα επηρεάσουν ορισμένους χρήστες, όπως η απόσυρση της βάσης “Popset”, ο τερματισμός υποστήριξης για ορισμένους τύπους εγγραφών (third party annotation) και αλλαγή σε ορισμένα πεδία που αφορούν τα γεωγραφικά μεταδεδομένα. Τέλος, δίνεται έμφαση στη στήριξη της κοινότητας μέσα από εκπαιδευτικές δράσεις.Ενδεικτικά αναφέρεται η συνεργασία, τον Ιούνιο του 2024, με τα “Αφρικανικά Κέντρα Ελέγχου” και “Πρόληψης Νόσων” για την οργάνωση τριήμερου εργαστηρίου σχετικά με την επιμέλεια δεδομένων αλληλουχίας παθογόνων οργανισμών.

Συνολικά, η αναφορά του GenBank αποτυπώνει έναν ώριμο, διαφανή θεσμό που υπηρετεί την ανοιχτή επιστήμη.Προάγει στην πράξη την συνεργασία μεταξύ θεσμών,εργαστηρίων και πολιτών, ενώ δεν παύει να αναπτύσσεται συνεχώς κάνοντας βήματα μπροστά, διορθώνοντας παράλληλα αστοχίες του παρελθόντος.Η κρίσιμη πρόκληση που το κείμενο θέτει, έμμεσα,είναι το πώς καθιστούμε αυτόν τον τεράστιο όγκο δεδομένων πραγματικά αναζητήσιμο.[13]

Κεφάλαιο 3

Αναζήτηση σε κλίμακα petabase: το MetaGraph

Αν το προηγούμενο κεφάλαιο περιέγραφε πώς αποθηκεύονται τα δεδομένα, το παρόν εξετάζει πώς τα αναζητούμε όταν φτάσουν σε κλίμακα "petabase" (δηλ 10^{15} νουκλεοτίδια). Σε αντίθεση με την αναφορά του GenBank, το έργο που εξετάζεται εδώ είναι μια πλήρης ερευνητική και μεθοδολογική εργασία, η οποία παρουσιάζει ένα εργαλείο, το MetaGraph, μαζί με τους αλγορίθμους, τις δομές δεδομένων και τις πειραματικές μετρήσεις απόδοσής του.

3.1 Το πρόβλημα της αναζήτησης πλήρους κειμένου

Το μέγεθος του προβλήματος αποτυπώνεται απλά με λίγους αριθμούς. Τα δημόσια αποθετήρια ακατέργαστων αναγνώσεων περιέχουν δεκάδες petabases δεδομένων, με τον όγκο τους να διπλασιάζεται περίπου κάθε 45 μήνες, σύμφωνα με το άρθρο.[7] Ο κλασικός τρόπος πρόσβασης σε αυτά τα δεδομένα βασίζεται στα μεταδεδομένα, δηλαδή ο ερευνητής αναζητά με βάση τον τίτλο, τον οργανισμό ή το άτομο που υπέβαλε τα δεδομένα στην βάση, εντοπίζει σχετικές εγγραφές και τις κατεβάζει για περαιτέρω επεξεργασία.

Αυτό που έλειπε ήταν η αναζήτηση πλήρους κειμένου. Πιο συγκεκριμένα η δυνατότητα να δοθεί μια αλληλουχία ως ερώτημα και να εντοπιστούν όλα τα σύνολα δεδομένων που την περιέχουν. Για ακατέργαστα δεδομένα κλίμακας petabase, μια τέτοια δυνατότητα θεωρούνταν επί μακρόν πρακτικά ανέφικτη, γεγονός που περιόριζε δραματικά τη δυνατότητα επαναξιοποίησής τους. Το φιλόδοξο ερώτημα που θέτουν οι συγγραφείς είναι αν μπορεί να κατασκευαστεί κάτι σαν ένα "Google για DNA", με προσιτό κόστος και όπως φαίνεται, η απάντηση που δίνουν είναι καταφατική.[7]

3.2 Ευρετηρίαση με annotated de Bruijn graphs

Ως λύση στο συγκεκριμένο πρόβλημα προτείνεται το "MetaGraph", ένα πλαίσιο που "ευρετηριάζει" (δηλ. κάνει indexing) αλληλουχίες DNA, RNA και πρωτεϊνών χρησιμοποιώντας επισημειωμένους γράφους "de Bruijn" (annotated de Bruijn graphs). Ένας "indexed και annotated" γράφος του MetaGraph στηρίζεται σε δύο βασικούς παράγοντες.

Ο πρώτος παράγοντας είναι ένα λεξικό k -mers που αναπαριστά τον γράφο de Bruijn. Όπως αναφέρθηκε στην εισαγωγή της παρούσας εργασίας, ένα k -mer είναι μια υποακολουθία μήκους k , δύο k -mers που επικαλύπτονται κατά $k - 1$ χαρακτήρες συνδέονται με μια κατευθυνόμενη ακμή. Στον γράφο de Bruijn, οι ακμές προκύπτουν πάντα από τους κόμβους, οπότε αρκεί να αποθηκευτεί το σύνολο των k -mers. Τα k -mers αυτά αποτελούν τα στοιχειώδη "tokens" πάνω στα οποία εκτελείται κάθε λειτουργία αναζήτησης.

Ο δεύτερος παράγοντας είναι ο πίνακας επισημείωσης (annotation matrix), ένας αραιός δυαδικός πίνακας $A \in \{0, 1\}^{n \times m}$, όπου n είναι το πλήθος των k -mers και m το πλήθος των ετικετών. Κάθε στοιχείο A_{ij} ισούται με 1 όταν το k -mer i σχετίζεται με το χαρακτηριστικό j , για παράδειγμα, όταν εμφανίζεται στο δείγμα j . Αυτή η σχέση μεταξύ k -mers και ετικετών είναι που μετατρέπει έναν απλό γράφο σε ένα πλήρες ευρετήριο ικανό να απαντήσει στο ερώτημα: «σε ποιο δείγμα εμφανίζεται μια συγκεκριμένη αλληλουχία;». Ο πίνακας μπορεί να έχει τεράστιες διαστάσεις, με το πλήθος των γραμμών του να φτάνει τάξεις μεγέθους έως και 10^{12} , είναι όμως εξαιρετικά αραιός και συνεπώς συμπίεσιμος.

Βέβαια το MetaGraph δεν περιορίζεται σε μία μόνο "βέλτιστη" υλοποίηση, αλλά προσφέρει πολλαπλές εναλλακτικές δομές δεδομένων για το πιο συμβατό αποτέλεσμα με βάσει τις διαφορετικές ανάγκες. Πιο αναλυτικά εξετάζει πάντα τον χώρο που καταλαμβάνει μια δομή, σε σχέση με την ταχύτητα την οποία απαιτείται για την απάντηση του εκάστοτε ερωτήματος. Αντί λοιπόν το σύστημα να επιβάλλει στον χρήστη κάποια υλοποίηση, τον αφήνει να επιλέξει. Ενδεικτικά, για την αποθήκευση των k -mers η πιο "συμπαγής" επιλογή αποτελεί η "SuccinctDBG" (θεμελιωμένη στον πίνακα BOSS), η οποία έχει ως προτεραιότητα την τχύτητα πρόσβασης σε σχέση με την συμπίεση, για αυτό ορίζεται και ως προεπιλογή. Εναλλακτικές μπορούν να βρεθούν σε απλούστερες υλοποιήσεις, όπως στην "HashDBG" που αναπαριστάται ως ένας πίνακας κατακερματισμού, στην "BitmapDBG" που αποθηκεύει τα k -mers σε ένα διάνυσμα δεικτών και σε αναπαράσταση του πίνακα επισημειώσεων, ο οποίος ανάλογα με το ερώτημα προσαρμόζεται και προσφέρει είτε γρήγορα ερωτήματα ανά γραμμή είτε ανά στήλη (row major και column major αντίστοιχα).

Ιδιαίτερη σημασία έχει η φάση της κατασκευής του γράφου από ακατέργαστα δεδομένα, καθώς εκεί εισάγεται ένα βήμα "καθαρισμού" που θα αποδειχθεί κρίσιμο τόσο για την αποτελεσματικότητα όσο και για τους περιορισμούς της μεθόδου. Αναλυτικότερα όταν ένας γράφος κατασκευάζεται από δεδομένα αλληλουχίας, περιέχει αναπόφευκτα k -mers που προέκυψαν από σφάλματα στην αλληλουχία (erroneous k -mers) και σχηματίζουν ψευδή μονοπάτια. Το MetaGraph εφαρμόζει διαδικασίες καθαρισμού που εντοπίζουν και απορρί-

πουν k -mers χαμηλής συχνότητας, με βάσει την υπόθεση ότι αυτά οφείλονται συνήθως σε σφάλματα ή μόλυνση. Η τυπική ροή εργασίας (workflow) για πολλαπλά δείγματα περιλαμβάνει τρία στάδια. Πρώτον την ανεξάρτητη κατασκευή ενός γράφου de Bruijn για κάθε δείγμα, στην συνέχεια τον καθαρισμό και την εξαγωγή συνεχόμενων αλληλουχιών (contigs) από τον καθένα, και τέλος τη συγχώνευση όλων σε έναν ενιαίο γράφο ο οποίος επισημειώνεται με τα αναγνωριστικά των δειγμάτων.

3.3 Οι τεχνικές συμπίεσης

Το πραγματικό επίτευγμα του MetaGraph έγκειται στη συμπίεση, καθώς τόσο το γράφημα αναπαράστασης όσο και ο πίνακας επισημείωσης μπορούν να λάβουν τεράστιες διαστάσεις. Για αποδοτικό αποτέλεσμα χρησιμοποιούνται τρεις κύριες τεχνικές. Πρώτον, η προεπιλεγμένη συμπίεσμένη αναπαράσταση, που αναφέραμε παραπάνω, βασίζεται σε "succinct data structures" και συγκεκριμένα στον πίνακα BOSS, ο οποίος αποθηκεύει το σύνολο των k -mers με ελάχιστο χώρο. Δεύτερον, η έννοια των "primary graphs" είναι πολύ σημαντική διότι εκμεταλλεύεται το γεγονός ότι κάθε k -mer μπορεί να εμφανιστεί σε δύο "προσανατολισμούς" (μπροστά και ανάστροφο συμπλήρωμα), αποθηκεύοντας μόνο τον έναν, μειώνοντας έτσι το μέγεθος του γράφου στο μισό. Τρίτον, και ίσως σημαντικότερο, η τεχνική "RowDiff" εκμεταλλεύεται το γεγονός ότι γειτονικοί κόμβοι του γράφου τείνουν να φέρουν σχεδόν ταυτόσημη επισημείωση, ούτως ώστε αποθηκεύοντας μόνο τις διαφορές μεταξύ γειτονικών κόμβων, αραιώνεται δραστικά ο πίνακας επισημείωσης και βελτιώνεται η συμπίεστικότητά του.

Όσον αφορά τα "primary graphs" αξίζει μια πιο προσεκτική ματιά, καθώς συνδέονται με έναν λεπτό αλλά ουσιώδη τεχνικό περιορισμό. Επειδή οι αναγνώσεις προέρχονται κατά βάση από άγνωστο κλώνο του DNA, κάθε αλληλουχία συμπληρώνεται με το ανάστροφο συμπλήρωμά της, ώστε ο γράφος να περιέχει κάθε k -mer και στους δύο κλώνους του DNA, (τέτοιοι γράφοι ονομάζονται canonical). Η αποθήκευση μόνο του λεξιλογικά μικρότερου από τους δύο κλώνους θα μείωνε το μέγεθος στο μισό, διότι εάν είναι γνωστή η μία αλυσίδα του DNA τότε είναι γνωστή και η άλλη. Αυτό όμως δεν συνδυάζεται αποδοτικά με τη συμπαγή αναπαράσταση BOSS, η οποία απαιτεί επικαλύψεις μεταξύ διαδοχικών k -mers. Οι συγγραφείς λοιπόν, λύνουν το πρόβλημα κατασκευάζοντας "primary graphs" τα οποία λειτουργούν ως εξής: κατά τη διάσχιση του canonical γράφου, καταγράφεται μόνο ο πρώτος κλώνος κάθε k -mer που συναντάται, αντι για τον μικρότερο λεξιλογικά, παράγοντας ένα σύνολο primary αλληλουχιών οι οποίες διατηρούν τις απαραίτητες επικαλύψεις και μπορούν στη συνέχεια να αναπαρασταθούν αποδοτικά με τον πίνακα BOSS, μειώνοντας έτσι το μέγεθος του γράφου έως και στο μισό.

Η αποδοτικότητα της αναζήτησης δεν οφείλεται μόνο στην συμπίεση αλλά και στον τρόπο και την ταχύτητα εκτέλεσης των ερωτημάτων. Στην πράξη σπάνια αναζητά κανείς μια μεμονωμένη αλληλουχία. Επομένως στο metagraph η ταχύτητα των ερωτημάτων επιτυγ-

χάνεται με έναν αλγόριθμο ομαδοποιημένης αναζήτησης (batched sequence query). Αντί να αναζητείται κάθε αλληλουχία ξεχωριστά, οι αλληλουχίες ενός ερωτήματος επεξεργάζονται συνολικά και σε στάδια. Αρχικά κατασκευάζεται ένας προσωρινός ενδιάμεσος γράφος από τις αλληλουχίες του ερωτήματος. Έπειτα από την τομή του ενδιάμεσου με τον μεγάλο ενιαίο γράφο παράγεται ένα υπογράφημα (query graph), που ήταν το ζητούμενο. Η προσέγγιση αυτή εκμεταλλεύεται την επικάλυψη k -mers μεταξύ των επιμέρους ερωτημάτων και επιτυγχάνει επιτάχυνση από δεκαπλάσια έως εκατονταπλάσια για επαναλαμβανόμενα ερωτήματα. Για τις περιπτώσεις όπου η απλή αντιστοίχιση k -mers δεν επαρκεί, δηλαδή όταν δεν υπάρχει ακριβές ταίριασμα (π.χ λόγω μετάλλαξης), προκειμένου να μην χαθεί η αλληλουχία, το MetaGraph υλοποιεί στοίχιση αλληλουχίας σε γράφο (sequence to graph alignment). Πιο αναλυτικά η στοίχιση αυτή δεν απαιτεί πλήρη επικάλυψη αλλά αναζητά το πλησιέστερο μονοπάτι μέσα στον γράφο ακολουθώντας μια προσέγγιση "seed and extend", γενίκευση του κλασικού αλγορίθμου τοπικής στοίχισης Smith-Waterman-Godoh.

3.4 Αποτελέσματα: κλίμακα, κόστος και ακρίβεια

Η αξιολόγηση του MetaGraph δεν περιορίζεται μόνο σε θεωρητικές μελέτες, αλλά στηρίζεται σε συστηματικά πειράματα που καλύπτουν τέσσερις άξονες, το μέγεθος του ευρετηρίου σε σύγκριση με ανταγωνιστικά εργαλεία, τους παράγοντες που καθορίζουν τον λόγο συμπίεσης, την ακρίβεια της ανάκτησης, και το τελικό κόστος της αναζήτησης.

Επεξηγηματικότερα το Metagraph σε σύγκριση με παρόμοια εργαλεία indexing, (μεταξύ αυτών τα COBS, kindex, Mantis, Bifrost, Themisto και Fulgor), είναι καλύτερο ως προς την συμπίεση χωρίς να υστερεί σε ταχύτητα. Επίσης ο λόγος συμπίεσης εξαρτάται καθοριστικά από το πλήθος και την ομοιότητα των δεδομένων (άλλα εργαλεία παρέχουν σταθερό λόγο ομοιότητας κάνοντας τα δύσχειστα σε κάποιες περιπτώσεις). Για ομοιογενή σύνολα "RNA-seq", όπως τα "cohorts" GTEx και TCGA, ο λόγος φτάνει αρκετές χιλιάδες βάσεις ανά byte, ενώ για ετερογενή, μη πλεοναστικά σύνολα, όπως συναρμολογημένα γονιδιώματα και πρωτεΐνες, πέφτει σε μονοψήφιες τιμές. Πέρα από το μέγεθος, εξετάστηκε κατά πόσο η αναζήτηση επιστρέφει σωστά αποτελέσματα. Οι μετρήσεις δείχνουν ότι η συντριπτική πλειονότητα των αναγνώσεων ταυτίζονται σε μεγάλο ποσοστό με τον γράφο του δείγματός τους.

Ως προς το κόστος, το ένα από τα πλέον εντυπωσιακά ευρήματα είναι ότι ένα πλήρες ευρετήριο του συνόλου των δημόσια διαθέσιμων αλληλουχιών θα χρειαζόταν μόλις μερικές εκατοντάδες terabytes χώρου. Το ίδιο προσιτή είναι και η αναζήτηση. Ένα μικρό ερώτημα (έως 1 megabase) κοστίζει περίπου 100 δολάρια, αλλά για μεγαλύτερα ερωτήματα το κόστος πέφτει κατακόρυφα, περίπου 0,74 δολάρια ανά megabase για την απλή αναζήτηση, και γύρω στα 18 δολάρια ανά megabase για την πιο απαιτητική στοίχιση, ακόμη κι όταν αυτή γίνεται σε ολόκληρο το "SRA". Το συμπέρασμα είναι εντυπωσιακό, το κόστος για να γίνει αναζητήσιμο το σύνολο των δεδομένων των "ENA" και "SRA" είναι ασήμαντο μπροστά

στο κόστος που χρειάστηκε για να παραχθούν αυτά τα δεδομένα εξαρχής

3.5 Εφαρμογές και περιορισμοί

Πέρα από τις μετρήσεις απόδοσης, το έργο παρουσιάζει πραγματικά παραδείγματα εξόρυξης που αναδεικνύουν τη χρησιμότητά του. Όπως χαρακτηριστικά αναφέρεται, ολόκληρη η βάση "CARD" και ένα σύνολο δεδομένων του "RefSeq" αναζητήθηκαν έναντι εκατοντάδων χιλιάδων δειγμάτων εντερικού μικροβιώματος, μια ανάλυση που με κλασικές μεθόδους θα απαιτούσε πρόσβαση σε εκατοντάδες terabytes ακατέργαστων δεδομένων, αλλά εδώ ολοκληρώθηκε σε έναν υπολογιστικό κόμβο μέσα σε περίπου μία ώρα! Σε ένα άλλο παράδειγμα, μελετήθηκαν χαρακτηριστικά όπως οι θέσεις ανάστροφης συρραφής (back splice junctions) που σχηματίζουν κυκλικά RNA. Τέτοιες ενώσεις είναι δύσκολο να εκφραστούν σε ένα κλασικό γραμμικό σύστημα συντεταγμένων, σε αντίθεση βέβαια με μια απεκόνιση γράφου. Αξιοποιώντας αυτό το πλεονέκτημα, με εργαλείο το Metagraph σαρώθηκαν συστηματικά εκατομμύρια πιθανές θέσεις ανάστροφης συρραφής στα δεδομένα των cohorts GTEx και TCGA, εντοπίζοντας χιλιάδες χρήσιμα δείγματα.

Στον αντίποδα οι ίδιοι οι συγγραφείς αναγνωρίζουν σαφείς περιορισμούς. Παρότι το Metagraph παρουσιάζεται ως "lossless" εργαλείο, τα indexes κατά περιπτώσεις παρουσιάζουν απώλειες καθώς κατά την διαδικασία καθαρισμού απορρίπτονται k -mers χαμηλής συχνότητας, τα οποία συνήθως αντιστοιχούν σε σφάλματα αλλά ενδέχεται να φέρουν και χρήσιμη πληροφορία. Επιπλέον, η χρήση στατικών δομών δεδομένων που εξασφαλίζει μέγιστη απόδοση και ελάχιστη κατανάλωση μνήμης, καθιστά δύσκολη την επέκταση ενός υπάρχοντος ευρετηρίου με νέα δείγματα. Τέλος, η ικανότητα της μεθόδου για στοίχιση των αλληλουχιών όταν υπάρχει μετάλλαξη (όπως ανφέρθηκε στην ενότητα 3.3) μειώνεται σε θορυβώδεις αλληλουχίες (όπως εκείνες της τεχνολογίας nanopore). Παρ' όλα αυτά το συγκεκριμένο έργο είναι μεγάλης σημασίας διότι μας δείχνει ότι η καθολική αναζήτηση σε δημόσια αποθετήρια είναι πλέον εφικτή και οικονομικά προσιτή.

Κεφάλαιο 4

Αξιοποίηση δεδομένων: εξόρυξη και εκτός στόχου αναγνώσεις

Έχοντας δει πώς αποθηκεύονται και πώς αναζητούνται τα δεδομένα, στρεφόμαστε τώρα στο ερώτημα του τι μπορεί να ανακαλύψει κανείς μέσα από αυτά. Το κεφάλαιο αυτό βασίζεται σε ένα review που εξετάζει την εξόρυξη δημόσιων γονιδιωματικών αποθετηρίων για τη μελέτη μικροβιακών παθογόνων οργανισμών.[11] Σε αντίθεση με τα δύο προηγούμενα έργα, εδώ δεν παρουσιάζεται νέο εργαλείο ούτε νέα δεδομένα, αλλά συντίθεται και οργανώνεται η υπάρχουσα βιβλιογραφία γύρω από μια ερευνητική πρακτική.

4.1 Η ιδέα των "εκτός στόχου αναγνώσεων"

Η κεντρική ιδέα του συγκεκριμένου "review" προκύπτει από μια απλή παρατήρηση. Συγκεκριμένα παρατηρείται ότι τα εργαλεία για μελέτη βιολογικών δεδομένων γίνονται πιο προσिता σε συνδιασμό ότι οι αντίστοιχες βάσεις δεδομένων διογκώνονται σε μέγεθος. Επομένως υπάρχει η πιθανότητα, η επαναχρησιμοποίηση κάποιων δεδομένων να βοηθήσει περαιτέρω έρευνες (μικροοργανισμών και μικρονβίων). Το κλειδί εδώ είναι η έννοια των εκτός στόχου αναγνώσεων (off-target reads).


Όταν ένας επιστήμονας ερευνά κάποιο γονίδιο ή κάποιο γονιδίωμα ενός οργανισμού, προκύπτουν πάντα χρήσιμα, ως προς την έρευνα δεδομένα, και κάποια δεδομένα που δεν σχετίζονται άμεσα. Επομένως τα μη χρήσιμα ως προς την έρευνα δεδομένα δεν αναλύονται περαιτέρω. Τα εν λόγω δεδομένα που προκύπτουν περιέχουν συχνά και αναγνώσεις που προέρχονται από άλλους οργανισμούς οι οποίοι ήταν παρόντες στο δείγμα. Σύνηθες παράδειγμα είναι η ύπαρξη παθογόνων μικροοργανισμών που μπορεί να πέρασαν απαρατήρητοι λόγω κάποιας λοίμωξης ή απλής έλλειψης ενδιαφέροντος του αρχικού ερευνητή. Οι αναγνώσεις αυτές αποτελούν έναν ανεξερεύνητο κομμάτι που ουσιαστικά επιτρέπουν τη μελέτη μικροβιακών παθογόνων χωρίς την "σπατάλη πόρων" για παραγωγή νέων δεδομένων, απλώς με την επαναχρησιμοποίηση όσων υπάρχουν ήδη δημόσια. Ένα άλλο πλεονέκτημα το οποίο είναι κι

αυτό ιδιαίτερης σημασίας, είναι το γεγονός ότι με την επαναχρησιμοποίηση μεγάλου μέρους ήδη υπάρχοντων δεδομένων μειώνεται κατά πολύ το "bias" των αποτελεσμάτων.

4.2 Μεθοδολογία: από την εξόρυξη στην ανάλυση

Το τεχνικό ζήτημα της παρούσας προσέγγισης είναι ακριβώς το πρόβλημα που αναλύθηκε στο προηγούμενο κεφάλαιο της εργασίας μας, δηλαδή το πώς γίνεται αναζήτηση σε βάσεις δεδομένων κλίμακας petabase, με αποδοτικό τρόπο. Ενδεικτικά αναφέρεται ότι οι βάσεις δεδομένων του "SRA" (Short reach archive) έχουν ήδη ξεπεράσει τα 53 petabases και εν συνεχεία παρουσιάζονται τα διαθέσιμα εργαλεία ευρετηρίασης που καθιστούν εφικτή την αναζήτηση. Μεταξύ αυτών ξεχωρίζουν το "STAT", που δέχεται ως ερώτημα έναν ταξινομικό όρο (taxon), το "MetaGraph", που δέχεται ως είσοδο μια αλληλουχία (βλέπε ενότητα 3), το "PebbleScout", επίσης για αναζήτηση με βάση την αλληλουχία και τέλος, το "Serratus", εξειδικευμένο στην ανακάλυψη ιών RNA. Τα τέσσερα αυτά εργαλεία δεν είναι ισοδύναμα, αλλά συμπληρωματικά, καθώς διαφέρουν ως προς τον τύπο του ερωτήματος και το πεδίο εφαρμογής τους. Από το κείμενο προκύπτει ότι ο συνδιασμός τέτοιων εργαλείων είναι αποδοτικός διότι το χτίσιμο ενός νέου ευρετηρίου από την αρχή είναι υπολογιστικά δαπανηρό, ενώ αντίθετα η αναζήτηση σε αυτό είναι εξαιρετικά γρήγορη. Λόγω ακριβώς αυτής της ασυμμετρίας, οι ομάδες που αναπτύσσουν τέτοια εργαλεία συχνά κατασκευάζουν το ευρετήριο μία φορά και το διαθέτουν δημόσια, ώστε οι υπόλοιποι ερευνητές να μπορούν να το αναζητούν χωρίς να το ξαναχτίζουν. Το μειονέκτημα είναι ότι ένα τέτοιο προκατασκευασμένο ευρετήριο αποτυπώνει λόγω χάρη το SRA σε μια δεδομένη χρονική στιγμή (καθώς το SRA διαρκώς επεκτείνεται) και όπως είναι φυσικό τα έτοιμα ευρετήρια δεν καλύπτουν πάντοτε το πλήρες ή το πλέον ενημερωμένο περιεχόμενό του.

Ακολουθώντας λοιπόν κάποια απ τις τεχνικές που αναφέρθηκαν ή συνδιασμό αυτών και αφού εντοπιστούν τα ζητούμενα δεδομένα, ακολουθεί μια σειρά βημάτων. Αρχικά, μετά την ανάκτηση, η λήψη των δεδομένων γίνεται συνήθως μέσω του "SRA Toolkit" ή απευθείας μέσω "FTP", ενώ τα συνοδευτικά μεταδεδομένα ανακτώνται από τη βάση "BioSample", είτε χειροκίνητα είτε προγραμματιστικά μέσω των "E-utilities" (τα ίδια εργαλεία πρόσβασης που περιγράφηκαν στο Κεφάλαιο 2). Έπειτα ακολουθεί ο έλεγχος και το φιλτράρισμα ποιότητας με εργαλεία όπως το "Trimmomatic", και προαιρετικά η αφαίρεση των αναγνώσεων του ξενιστή (host read depletion). Στη συνέχεια ανοίγονται διαφορετικά μονοπάτια ανάλυσης, ανάλογα με τον στόχο του εκάστοτε μελετητή π.χ η χαρτογράφηση (mapping) και η ανίχνευση παραλλαγών (SNP calling) οδηγούν σε φυλογενετική ανάλυση ενώ η "de novo" οδηγεί σε δομική και συγκριτική γονιδιωματική. Επιπρόσθετα εργαλεία όπως το "Kraken2" ή το "BLAST" οδηγούν στη μελέτη των κοινοτήτων μικροβιώματος. Καθένα από αυτά τα μονοπάτια απαιτεί πολλαπλά αναλυτικά βήματα και εξειδικευμένα εργαλεία. Μια αναπαράσταση αυτών των μονοπατιών ακολουθεί στην παρακάτω εικόνα.



Σχήμα 4.1: Σχηματική αναπαράσταση των πιθανών ροών ανάλυσης μετά την εξόρυξη δεδομένων.

4.3 Τα τρία μεγάλα οφέλη

Αφού αναλύθηκαν η βασική ιδέα και οι συνηθισμένες μέθοδοι εξόρυξης και ανάλυσης των δεδομένων, κρίνεται απαραίτητο να γίνει περαιτέρω εμβάθυνση στα οφέλη της "off target read" πρακτικής. Η συγκεκριμένη αναφορά οργανώνεται γύρω από τρεις άξονες συνεισφοράς, καθένας από τους οποίους συνοδεύεται από σχετικά παραδείγματα.

Ο πρώτος άξονας αφορά την επέκταση και την εκ νέου αναζήτηση σε ήδη γνωστές αλληλουχίες οργανισμών, με την προοπτική της εύρεσης χρήσιμων δεδομένων και παραλλαγών. Το πλέον χαρακτηριστικό παράδειγμα αφορά το ρύζι το οποίο μέχρι πρότινος ήταν γνωστό ότι μολύνεται από συγκεκριμένους ιούς, όμως μέσω ανάλυσης χιλιάδων συνόλων γονιδίων RNA ρυζιού από το SRA, ανακαλύφθηκαν νέοι ιοί. Στην ιατρική, η αναζήτηση σε βάσεις δεδομένων γονιδίων RNA οδήγησε στην ταυτοποίηση δεκάδων χιλιάδων νέων ιών

RNA. Το φαινόμενο αυτό δεν περιορίζεται στους ιούς ούτε μόνο στο πεδίο της ιατρικής και της βιολογίας καθώς η ίδια λογική έχει εφαρμοστεί ακόμη και σε αρχαίο DNA, με χαρακτηριστικό παράδειγμα τον εντοπισμό μιας υποομάδας του βακτηρίου "*Clostridium tetani*" μέσα σε αρχαιολογικά δείγματα, γεγονός που το καθιστά ως μεγάλη αρχαιολογική ανακάλυψη. Τέτοιες ανακαλύψεις δεν εμπλουτίζουν μόνο την συλλογή όπως αποδείχθηκε. Όπως είναι φανερό έχουν και πρακτικό όφελος αφού μπορούν να αναδείξουν παθογόνα με δυνητικό κίνδυνο εμφάνισης, ενώ ταυτόχρονα διορθώνουν τη μεροληψία των υπάρχοντων συλλογών, οι οποίες συχνά στηρίζονται σε στελέχη ιών που σχετίζονται με γνωστές εξάρσεις νόσων, αφήνοντας έξω μεγάλο μέρος της πραγματικής ποικιλότητας.

Το δεύτερο σκέλος αφορά την "In Silico" παρατήρηση-επιτήρηση επιδημιών. Κάποιες φορές τα δεδομένα που ανακαλύπτονται δεν μπορούν να δώσουν την πλήρη εικόνα στους επιστήμονες που τα μελετούν, ιδιαίτερα σε περιπτώσεις που μελετούνται γονίδια παθογόνων οργανισμών μια επιδημίας ή πανδημίας. Λύση σε αυτό το πρόβλημα δίνουν συχνά τα μεταδεδομένα. Τα μεταδεδομένα είναι συμπληρωματικά δεδομένα που συνήθως αφορούν τοποθεσίες και ημερομηνίες που συνοδεύουν τα "κυρίως δεδομένα" της έρευνας και επιτρέπουν τον εμπλουτισμό της γνωστής χωροχρονικής κατανομής των παθογόνων, αποκαλύπτοντας ενδεχομένως προηγούμενες μη ανιχνευμένες εμφανίσεις. Ενδεικτικά όπως αναφέρουν οι συγγραφείς, η εξόρυξη δεδομένων έχει χρησιμοποιηθεί για τον επαναπροσδιορισμό του χρονοδιαγράμματος και της γεωγραφικής εξάπλωσης ιικών παθογόνων των φυτών, καθώς και για την επιβεβαίωση της ενδημικότητας βακτηρίων σε συγκεκριμένες περιοχές. Έτσι, η εξόρυξη δεδομένων λειτουργεί συμπληρωματικά προς την παραδοσιακή επιδημιολογική επιτήρηση και τροφοδοτεί μοντέλα εξάπλωσης και εξέλιξης.

Τέλος ο τρίτος άξονας αφορά την έρευνα αλληλεπιδράσεων εντός ενός οικοσυστήματος. Όπως είναι φυσικό σε κάθε οικοσύστημα, είτε αυτό αφορά τον μακρόκοσμο είτε τον μικρόκοσμο, υπάρχει πάντα αλληλεπίδραση μεταξύ των οργανισμών. Στην συγκεκριμένη περίπτωση γίνεται λόγος για τα μικροβιακά παθογόνα τα οποία εμπλέκονται σε σύνθετες σχέσεις με ξενιστές, φορείς (vectors) και μικροβιακές κοινότητες. Έτσι η εξόρυξη δεδομένων βοηθά στην ανακάλυψη ή την επέκταση του εύρους ξενιστών καθώς και στην εξακρίβωση της ύπαρξης ή μη κάποιου ξενιστή στην "δεξαμενή" δεδομένων ενός παθογόνου. Ένα εντυπωσιακό παράδειγμα της απρόβλεπτης φύσης τέτοιων ευρημάτων είναι ο εντοπισμός ενός νέου ιού που φαίνεται να μολύνει το παράσιτο "*Toxoplasma gondii*", ο οποίος προέκυψε από την ανάλυση δεδομένων ανθρώπινων νευρωνικών κυττάρων. Η εύρεση του συγκεκριμένου ιού είναι υψίστης σημασίας καθώς βρέθηκε εντός ενός παρασίτου το οποίο με τη σειρά του βρισκόταν εντός ανθρώπινου ιστού, πράγμα που κανένα στοχευμένο πείραμα δεν είχε σχεδιαστεί να αποκαλύψει.

4.4 Προκλήσεις και καλές πρακτικές

Το κύριο πρόβλημα των off target αναγνώσεων είναι η ποιότητα των μεταδεδωμένων. Το συχνότερο πρόβλημα είναι η έλλειψη αυτών ή κάποιου μέρους από αυτά. Συγκεκριμένα αναφέρεται ότι τα πεδία του ξενιστή, της τοποθεσίας και της ημερομηνίας είναι συχνά ελλιπή ή ανακριβή, ενώ η σημασία τους μπορεί να είναι διφορούμενη. Παραδήγηματος χάρη, η ημερομηνία μπορεί να αναφέρεται στην διαδικασία επεξεργασίας της αλληλουχίας αντί για τη δειγματοληψία.

Το δεύτερο μεγάλο πρόβλημα αφορά τη μόλυνση των δεδομένων. Πρόκειται για περιπτώσεις όπου το γενετικό υλικό δεν προέρχεται από το συγκεκριμένο δείγμα, είτε λόγω εξωτερικής μόλυνσης από τον εργαστηριακό εξοπλισμό είτε λόγω διασταυρούμενης μόλυνσης μεταξύ δειγμάτων. Το ζήτημα είναι ιδιαίτερα κρίσιμο για τα παθογόνα, που εμφανίζονται σε χαμηλές συχνότητες μέσα στις αναγνώσεις του ξενιστή, και οι κλασικές μέθοδοι αντιμετώπισης της μόλυνσης δυστυχώς δεν προσαρμόζονται εύκολα στην εκ των υστέρων επαναχρησιμοποίηση δεδομένων.

Εν κατακλείδι παρά όλα τα οφέλη, ο συνδυασμός αυτών των περιορισμών επιβάλλει μια συγκεκριμένη μεθοδολογική στάση. Συγκεκριμένα τα αποτελέσματα της εξόρυξης δεδομένων θα πρέπει να θεωρούνται προκαταρκτικά και να επιβεβαιώνονται με ανεξάρτητες πηγές, είτε μέσω πολλαπλών ανεξάρτητων συνόλων δεδομένων είτε μέσω αποκλειστικών, εκ νέου μελετών. Υπό αυτή την έννοια κρίνεται ότι η εξόρυξη δεδομένων δεν μπορεί να υποκαταστήσει τις αποκλειστικές μελέτες, αποτελεί όμως ένα ισχυρό συμπληρωματικό εργαλείο και ένα εξαιρετικό εφελκτήριο για τη διατύπωση υποθέσεων.

Κεφάλαιο 5

Ανάλυση αλληλουχιών με τεχνητή νοημοσύνη

Το τελευταίο κεφάλαιο της παρούσας εργασίας κλείνει τον "κύκλο ζωής" των δεδομένων εξετάζοντας πώς, αφού αποθηκευτούν, αναζητηθούν και αξιοποιηθούν, οι αλληλουχίες αναλύονται με μεθόδους τεχνητής νοημοσύνης. Βασίζεται σε μια εκτενή, συστηματική ανασκόπηση που χαρτογραφεί το πεδίο της ανάλυσης αλληλουχιών DNA με τεχνικές μηχανικής και βαθιάς μάθησης, ενώ αντίστοιχες κριτικές ανασκοπήσεων επιβεβαιώνουν τις ίδιες τάσεις του πεδίου [9].

5.1 Το χάσμα μεταξύ βιολογίας και τεχνητής νοημοσύνης

Η ανάλυση αλληλουχιών DNA με παραδοσιακά εργαστηριακά πειράματα είναι πολλές φορές δαπανηρή, χρονοβόρα και επιρρεπής σε σφάλματα. Παράλληλα η συνεχής παραγωγή νέου όγκου δεδομένων από νέες τεχνολογίες "NGS" κάνει πιο επιτακτική την ανάγκη νέων μεθόδων ανάλυσης. Έτσι προάγεται η χρήση μεθόδων τεχνητής νοημοσύνης για την ανάλυση αλληλουχιών DNA. Οι μέθοδοι αυτές δεν αντικαθιστούν τα πειράματα, αλλά τα συμπληρώνουν, βοηθώντας στη διατύπωση υποθέσεων και στην ερμηνεία μοτίβων μέσα σε μεγάλα γονιδιωματικά σύνολα. Συγκεκριμένα τεχνικές μηχανικής και βαθιάς μάθησης χρησιμοποιούνται για την αυτοματοποιημένη αναγνώριση προτύπων και την πρόβλεψη βιολογικών χαρακτηριστικών μέσα από τις αλληλουχίες του DNA.

Βέβαια η όλη διαδικασία δεν στερείται εμποδίων. Το κεντρικό πρόβλημα που εντοπίζεται είναι ένα χάσμα πεδίων (domain gap), όπως χαρακτηριστικά αναφέρεται, οι μοριακοί βιολόγοι γνωρίζουν ποιες αναλυτικές εργασίες (tasks) έχουν σημασία κατά την επεξεργασία γονιδίων, αλλά δεν γνωρίζουν απαραίτητα ποια υπολογιστική μέθοδος είναι η κατάλληλη για να τους βοηθήσει. Αντίστροφα, οι επιστήμονες υπολογιστών γνωρίζουν τα μοντέλα, αλλά όχι τη βιολογική φύση των εργασιών. Προκειμένου να γεφυρωθεί αυτό

το χάσμα, παρουσιάζονται 44 διακριτές εργασίες ανάλυσης DNA. Ως εργασία (task) νοείται ένα συγκεκριμένο βιολογικό πρόβλημα που επιχειρεί να επιλύσει ένα υπολογιστικό μοντέλο χρησιμοποιώντας ως είσοδο αλληλουχίες DNA. Αυτές οι εργασίες με την σειρά τους εντάσσονται σε 8 βιολογικούς στόχους, που αντιστοιχούν σε 36 βιολογικές βάσεις δεδομένων και 140 σύνολα αναφοράς (benchmark datasets).[1]

Η εφαρμογή της τεχνητής νοημοσύνης στις παραπάνω εργασίες ακολουθεί μια γενική διαδικασία τεσσάρων βασικών σταδίων. Αρχικά γίνεται η συλλογή και κατασκευή συνόλων δεδομένων από δημόσιες βάσεις. Έπειτα ακολουθεί, ίσως το κρίσιμότερο στάδιο, το οποίο αφορά τη μετατροπή των βάσεων των γονιδίων (A,G,T κ.τ.λ) σε αριθμητικά διανύσματα με τις κατάλληλες μεθόδους αναπαράστασης (βλέπε 5.3). Εν συνεχεία απαραίτητη είναι η εκπαίδευση μηχανισμών πρόβλεψης (predictors) που μαθαίνουν μοτίβα που σχετίζονται με το εκάστοτε βιολογικό πρόβλημα. Τέλος με τις κατάλληλες μετρικές γίνεται η αξιολόγηση της απόδοσης του μοντέλου.

5.2 Οι εργασίες και οι βιολογικοί στόχοι

Όπως αναφέρθηκε και παραπάνω, προκειμένου να υπάρξει κοινός κώδικας για να γεφυρωθεί το χάσμα μεταξύ των δύο επιστημονικών πεδίων παρέχεται μια διπλή κατηγοριοποίηση των 44 εργασιών. Από βιολογική σκοπιά, οι εργασίες ομαδοποιούνται σε 8 στόχους:

- Δομή και σταθερότητα του γονιδιώματος: Περιλαμβάνει εργασίες που σχετίζονται με την οργάνωση και τη διατήρηση του γονιδιώματος, όπως η πρόβλεψη σημείων έναρξης αντιγραφής και ο εντοπισμός της θέσης των νουκλεοτιδίων.[6]
- Ρύθμιση της γονιδιακής έκφρασης
- Ανάλυση γονιδίων:Αφορά την αναγνώριση και πρόβλεψη χαρακτηριστικών που σχετίζονται με τη λειτουργία και την έκφραση των γονιδίων.
- Ανάλυση γονιδιακών δικτύων:Εξετάζει τις σχέσεις και τις αλληλεπιδράσεις μεταξύ διαφορετικών γονιδίων.
- Πρόβλεψη τροποποιήσεων του DNA: αφορά χημικές τροποποιήσεις, όπως η μεθυλίωση, που δεν αλλάζουν την ίδια την αλληλουχία αλλά ρυθμίζουν τη λειτουργία των γονιδίων [12].
- Λειτουργική ανάλυση:Εστιάζει στην αναγνώριση λειτουργικών χαρακτηριστικών και περιοχών των αλληλουχιών DNA.
- Περιβαλλοντική και μικροβιακή ανάλυση γονιδιακών δεδομένων
- Ανάλυση νόσων:Περιλαμβάνει εργασίες που συνδέουν πληροφορίες των αλληλουχιών DNA με παθογόνους οργανισμούς και ασθένειες.

Από υπολογιστική σκοπιά, οι ίδιες εργασίες αναδιατυπώνονται σε τρεις θεμελιώδεις τύπους προβλημάτων:

- Ταξινόμηση(Classification):Το μοντέλο καλείται να τοποθετήσει μια αλληλουχία σε μία ή περισσότερες προκαθορισμένες κατηγορίες. Η ταξινόμηση μπορεί να είναι δυαδική, πολλαπλών κλάσεων ή πολλαπλών ετικετών.
- Παλινδρόμηση(Regression):Το ζητούμενο δεν είναι η επιλογή μιας κατηγορίας, αλλά η πρόβλεψη μιας συνεχούς αριθμητικής τιμής.
- Ομαδοποίηση(Clustering):Το μοντέλο οργανώνει τις αλληλουχίες σε ομάδες με βάση τις μεταξύ τους ομοιότητες, χωρίς να απαιτούνται προκαθορισμένες κατηγορίες.

Αυτή η αντιστοίχιση είναι πρακτικά χρήσιμη, καθώς επιτρέπει σε έναν επιστήμονα υπολογιστών να επιλέξει τον κατάλληλο αλγόριθμο ανάλογα με τον τύπο της εργασίας, χωρίς να χρειάζεται εις βάθος βιολογική γνώση.

5.3 Αναπαράσταση αλληλουχιών

Ένα από τα σημαντικότερα στάδια της αναλυτικής διαδικασίας είναι η αναπαράσταση του DNA. Όπως αναφέρθηκε και στην ενότητα 5.1 οι αλγόριθμοι μηχανικής και βαθιάς μάθησης δεν μπορούν να επεξεργαστούν απευθείας τις ακατέργαστες αλληλουχίες που αποτελούνται από τα σύμβολα A, C, G και T, αλλά απαιτούν τη μετατροπή τους σε αριθμητική μορφή. Η επιλογή της κατάλληλης αναπαράστασης είναι επομένως ιδιαίτερα σημαντική, καθώς καθορίζει ποια χαρακτηριστικά της αρχικής αλληλουχίας θα διατηρηθούν.

Πριν από τις σύγχρονες μεθόδους, αξίζει να σημειωθεί ότι οι απλούστερες προσεγγίσεις αναπαράστασης όπως η κωδικοποίηση "one hot", όπου κάθε νουκλεοτίδιο ή k -mer αντιστοιχεί σε ένα αραιό δυαδικό διάνυσμα, ή η αναπαράσταση με βάση τη συχνότητα των k -mers έχουν το μειονέκτημα ότι δεν συλλαμβάνουν τη σημασιολογική σχέση μεταξύ των υποακολουθιών.

Για την αντιμετώπιση αυτών των περιορισμών έχουν εφαρμοστεί στην ανάλυση DNA οι ενσωματώσεις λέξεων (word embeddings). Μέθοδοι όπως το "Word2Vec", το "GloVe" και το "FastText" αντιστοιχίζουν σε κάθε k -mer ένα πυκνό διάνυσμα σε έναν συνεχή χώρο, με τέτοιο τρόπο ώστε k -mers που εμφανίζονται σε παρόμοια συμφραζόμενα να βρίσκονται κοντά μεταξύ τους. Το Word2Vec, για παράδειγμα, μαθαίνει αυτές τις αναπαραστάσεις με δύο εναλλακτικές αρχιτεκτονικές προβλέποντας ένα k -mer από τα γειτονικά του (Continuous Bag of Words) ή αντίστροφα, προβλέποντας τα γειτονικά από ένα κεντρικό k -mer (skip-gram). Πέρα από αυτές, υπάρχουν και μέθοδοι βασισμένες σε γράφους, όπως το "Node2Vec" και το "DeepWalk", οι οποίες κατασκευάζουν έναν γράφο από τα k -mers και μαθαίνουν αναπαραστάσεις εκτελώντας τυχαίους περιπάτους (random walks) πάνω στη

συνδεσιμότητά του μια ιδέα εννοιολογικά συγγενική με τους γράφους de Bruijn (βλέπε ενότητα 3).

Η χαρτογράφηση της βιβλιογραφίας από τους συγγραφείς δείχνει ότι έχουν ήδη χρησιμοποιηθεί 12 διαφορετικές τεχνικές word embeddings σε εφαρμογές ανάλυσης DNA. Παράλληλα, εντοπίζονται 17 διαφορετικές μέθοδοι που έχουν εφαρμοστεί σε άλλους τύπους βιολογικών αλληλουχιών, όπως RNA και πρωτεΐνες, αλλά δεν είχαν ακόμη αξιοποιηθεί αντίστοιχα στο DNA. Το εύρημα αυτό δείχνει ότι, παρά τη σημαντική ανάπτυξη των μεθόδων αναπαράστασης, εξακολουθούν να υπάρχουν αρκετές τεχνικές των οποίων η χρησιμότητα για την ανάλυση DNA δεν έχει διερευνηθεί.

5.4 Γλωσσικά μοντέλα και Transformers

Μια διαφορετική προσέγγιση αποτελούν τα γλωσσικά μοντέλα (language models). Τα μοντέλα αυτά ακολουθούν το παράδειγμα της "προεξπαίδευσης και εξειδίκευσης" (pretraining and fine tuning). Αρχικά εκπαιδεύονται με μη επιβλεπόμενο τρόπο σε τεράστιες ποσότητες αλληλουχιών, μαθαίνοντας γενικές αναπαραστάσεις, και έπειτα προσαρμόζονται σε μια συγκεκριμένη εργασία με σχετικά λίγα επισημειωμένα δεδομένα. Με τον τρόπο αυτό, η γνώση που αποκτήθηκε κατά την προεξπαίδευση μπορεί να αξιοποιηθεί σε διαφορετικές επιμέρους εργασίες, χωρίς κάθε μοντέλο να χρειάζεται να εκπαιδεύεται εξ ολοκλήρου από την αρχή. Επιπρόσθετα άξια ανφοράς είναι τα μοντέλα βασισμένα στην αρχιτεκτονική "Transformer" όπως τα "BERT", "GPT-3", "XLNet", "ELECTRA" και "ALBERT" τα οποία μαθαίνουν αναπαραστάσεις προβλέποντας "κρυμμένα" k -mers με βάση τα συμφραζόμενά τους, αξιοποιώντας τον μηχανισμό της προσοχής (attention) για να συλλάβουν σχέσεις γονιδίων ακόμα και αν η απόστασή τους είναι μεγάλη μέσα στην αλληλουχία. Ιδίως το "BERT", με τη διπλής κατεύθυνσης φύση του που λαμβάνει υπόψη ταυτόχρονα συμφραζόμενα και από δεξιά και από αριστερά, αναδεικνύεται συστηματικά ως το "εργαλείο" με τις καλύτερες επιδόσεις στην πλειονότητα των εργασιών. Παρά τα πλεονεκτήματα των συγκεκριμένων αναπαραστάσεων όμως η ανάγκη για μεγάλο όγκο δεδομένων εκπαίδευσης και σημαντικούς υπολογιστικούς πόρους προϋποθέτει και αύξηση στο κόστος.

5.5 Predictors, αξιολόγηση και τάσεις

Μετά την παραγωγή της κατάλληλης αριθμητικής αναπαράστασης, ακολουθεί το στάδιο της "πρόβλεψης". Τα διανύσματα που έχουν προκύψει χρησιμοποιούνται ως είσοδο σε έναν "predictor", δηλαδή στον αλγόριθμο που μαθαίνει να αντιστοιχίζει τα χαρακτηριστικά της αλληλουχίας στην επιθυμητή έξοδο. Οι αλγόριθμοι αυτοί, διακρίνονται σε αλγόριθμους μηχανικής μάθησης και βαθιάς μάθησης. Όπως είναι φανερό όμως, η επιλογή του κατάλληλου "προβλέπτη" εξαρτάται από τον τύπο της εργασίας που καλείται να εξυπηρετήσει.

Παραδείγματος χάρι ένα πρόβλημα δυαδικής ταξινόμησης απαιτεί διαφορετική έξοδο από ένα πρόβλημα παλινδρόμησης.

Σε επόμενο στάδιο ακολουθεί η αξιολόγηση της αποδοσης των μοντέλων η οποία γίνεται με καθιερωμένες μετρικές προσαρμοσμένες στον τύπο της κάθε εργασίας. Για τα προβλήματα ταξινόμησης χρησιμοποιούνται μετρικές όπως η ακρίβεια (accuracy), η ακρίβεια θετικών προβλέψεων (precision), η ανάκληση (recall), το "F1-score" και ο συντελεστής συσχέτισης Matthews (MCC), ο οποίος είναι ιδιαίτερα χρήσιμος σε μη ισορροπημένα σύνολα δεδομένα. Αντίστοιχα για τα προβλήματα παλινδρόμησης χρησιμοποιούνται μετρικές οι οποίες αποτιμούν το σφάλμα ή τη συσχέτιση μεταξύ πραγματικών και προβλεπόμενων τιμών.

5.6 Περιορισμοί και προβλήματα συγκριτικής αξιολόγησης

Όπως είναι λογικό η αξιολόγηση δεν αποτελεί απλώς το τελευταίο τεχνικό βήμα της διαδικασίας, αλλά προϋπόθεση για την αξιόπιστη σύγκριση διαφορετικών προσεγγίσεων. Μια υψηλή τιμή σε μία μετρική δεν αρκεί από μόνη της για να αποδείξει ότι ένα μοντέλο είναι συνολικά καλύτερο, ιδιαίτερα όταν οι μελέτες χρησιμοποιούν διαφορετικά σύνολα δεδομένων, διαφορετικούς τρόπους διαχωρισμού τους και διαφορετικές διαδικασίες αξιολόγησης. Ένας άλλος παράγοντας ο οποίος συχνά δυσχεραίνει την αντικειμενική σύγκριση μεταξύ των διαφορετικών μοντέλων είναι η χρήση διαφορετικών "datasets", διαφορετικές διαδικασίες προεπεξεργασίας και διαφορετικά πειραματικά πρωτόκολλα. Επιπρόσθετα οι ερευνητές τείνουν να κατασκευάζουν νέα σύνολα δεδομένων αντί να χρησιμοποιούν τα υπάρχοντα, με αποτέλεσμα να καθίσταται αδύνατη η δίκαιη σύγκριση μεταξύ των μεθόδων. Επιπλέον, πολλές μελέτες δεν δημοσιεύουν τον πηγαίο κώδικά τους, υπονομεύοντας την αναπαραγωγιμότητα. Μια ενδεικτική λύση σε αυτό θα μπορούσε να ήταν η καθιέρωση τυποποιημένων συνόλων αναφοράς και η υποχρεωτική διάθεση του κώδικα που χρησιμοποιήθηκε.

Κεφάλαιο 6

Πρόσθετο υλικό & μελλοντικές εφαρμογές

Φτάνοντας προς το τέλος της παρούσας εργασίας, αξίζει να αναφερθούν ορισμένες πρόσθετες εφαρμογές και μελλοντικές κατευθύνσεις που σχετίζονται με τη διαχείριση και ανάλυση δημόσιων βιολογικών δεδομένων. Δεδομένου ότι οι ανάγκες για αποθήκευση, αναζήτηση και αξιοποίηση αλληλουχιών αυξάνονται διαρκώς, διεξάγεται συνεχώς ερευνητικό έργο και αναπτύσσονται νέες μέθοδοι, πολλές από τις οποίες χτίζουν απευθείας πάνω στους άξονες που εξετάστηκαν στα προηγούμενα κεφάλαια.

6.1 Αξιοποίηση εκτός στόχου αναγνώσεων σε νέα πεδία

Όπως αναλύθηκε στο Κεφάλαιο 4, η πρακτική της αξιοποίησης εκτός στόχου αναγνώσεων αποτελεί ισχυρό εργαλείο για τη μελέτη μικροβιακών παθογόνων. Αξίζει να αναφερθεί ότι η προσέγγιση αυτή εφαρμόζεται ήδη σε νέα, ανεξάρτητα μεταξύ τους πεδία. Στον χώρο της υδατοκαλλιέργειας, οι μη χαρτογραφημένες αναγνώσεις δεδομένων γονιδιωμάτων χιλιάδων εκτρεφόμενων ψαριών αξιοποιήθηκαν για την αναδρομική επιτήρηση παθογόνων και τη μελέτη της μετάβασης από το μικροβίωμα στο "παθοβίωμα", χωρίς επιπλέον κόστος αλληλούχισης [19]. Σε εντελώς διαφορετικό πλαίσιο, εκείνο της εξελικτικής οικολογίας, η ίδια λογική αξιοποιήθηκε για την ανίχνευση των οργανισμών (νηματωδών, βακτηρίων, συμβιώντων) που συνδέονται με το δασικό παράσιτο "Ips typographus" [10]. Τα δύο αυτά παραδείγματα δείχνουν ότι η επαναχρησιμοποίηση θεωρητικά "άχρηστων" δεδομένων μπορεί να επεκταθεί σε οποιονδήποτε κλάδο παράγει μαζικά δεδομένα αλληλουχιών, και να παράξει χρήσιμα αποτελέσματα.

6.2 Η επόμενη γενιά αναζήτησης σε αποθετήρια

Οι περιορισμοί του MetaGraph που εντοπίστηκαν στο Κεφάλαιο 3 όπως η μειωμένη ευαισθησία σε θορυβώδεις αλληλουχίες και η δυσκολία επέκτασης στατικών ευρετηρίων ορίζουν ενεργές κατευθύνσεις της τρέχουσας έρευνας. Άξιες αναφοράς είναι δύο πρόσφατες μελέτες που όπως φαίνεται εξερευνούν αυτές τις αδυναμίες με στόχο να δώσουν λύση. Η πρώτη συνδιάζει την αναζήτηση σε κλίμακα SRA με τεχνικές ενσωματώσεων (embeddings), ώστε αυτή να γίνει ανθεκτική στον θόρυβο και στις μεταλλάξεις [17]. Η δεύτερη προτείνει ένα δυναμικό, συνεχώς ενημερωμένο ευρετήριο που ξεπερνά τον περιορισμό των στατικών δομών, επιτρέποντας την ενσωμάτωση νέων δειγμάτων χωρίς πλήρη ανακατασκευή ολόκληρων βάσεων δεδομένων[15]. Και οι δύο δείχνουν ότι η ιδέα ενός "Google για DNA" εξακολουθεί να ωριμάζει.

6.3 Η υποδομή δεδομένων ως θεμέλιο

Πέρα από τις επιμέρους μεθόδους αναζήτησης, εξόρυξης και ανάλυσης, κοινό υπόβαθρο όλων αποτελεί η ίδια η υποδομή των δεδομένων, δηλαδή τα αποθετήρια, τα εργαλεία και τα τυποποιημένα μορφότυπα που τη συγκροτούν. Καμία από τις προηγούμενες κατευθύνσεις δεν μπορεί να προχωρήσει αν η βάση πάνω στην οποία στηρίζεται δεν είναι αξιόπιστη, πλήρης και προσβάσιμη.

Όπως αναλύθηκε στο Κεφάλαιο 2, αποθετήρια όπως το GenBank δεν αποτελούν στατικές αποθήκες, αλλά εξελίσσονται διαρκώς. Οι κατευθύνσεις της εξέλιξής τους αποτεούν η ταχύτερη δημοσίευση αλληλουχιών κατά τα πρότυπα της απόκρισης σε πανδημίες, ο αυστηρότερος έλεγχος "μόλυνσης" δεδομένων πριν από την κατάθεση, και η βελτίωση της πληρότητας και της τυποποίησης των μεταδεδομένων δεν είναι δευτερεύουσες τεχνικές λεπτομέρειες [13]. Αντιθέτως, καθορίζουν άμεσα τι είναι εφικτό στα επόμενα στάδια. Η ποιότητα των μεταδεδομένων, για παράδειγμα, είναι ακριβώς εκείνη που περιορίζει την αξιοπιστία της εξόρυξης δεδομένων (Κεφάλαιο 4), ενώ η δομή και η καθαρότητα των αλληλουχιών επηρεάζει την αποδοτικότητα της αναζήτησης (Κεφάλαιο 3) και της ανάλυσης με τεχνητή νοημοσύνη (Κεφάλαιο 5).

Στην κατεύθυνση αυτή, αξίζει να αναφερθεί μια πρόσφατη ανασκόπηση που προσφέρει μια συνολική, λειτουργική επισκόπηση των εργαλείων, των βάσεων δεδομένων και των μορφότυπων που χρησιμοποιούνται στις σύγχρονες ροές εργασίας πάνω σε αλληλουχίες του DNA [4]. Τέτοιοι πόροι αποκτούν ολοένα μεγαλύτερη αξία, καθώς η αυξανόμενη πολυπλοκότητα του οικοσυστήματος καθιστά την τυποποίηση και τη σαφή τεκμηρίωση, προϋπόθεση για την αποδοτική επαναχρησιμοποίηση των δεδομένων. Έτσι, η συνεχής βελτίωση και τυποποίηση αυτής της υποδομής, με βάση τις αρχές FAIR, αποτελεί έναν από τους πιο θεμελιώδεις στόχους για το μέλλον του πεδίου.

6.4 Σύγκλιση τεχνητής νοημοσύνης και αλληλούχησης

Η ευρύτερη και ίσως σημαντικότερη τάση του πεδίου είναι η ενσωμάτωση της τεχνητής νοημοσύνης σε ολόκληρο τον κύκλο ζωής των δεδομένων, από την ίδια την ανάγνωση των γονιδίων και των γονιδιωμάτων έως την τελική ανάλυση. Αν το Κεφάλαιο 5 έδειξε πώς η TN αναλύει ήδη υπάρχουσες αλληλουχίες, η τρέχουσα έρευνα κινείται προς μια βαθύτερη κατεύθυνση, όπου τα ίδια τα μοντέλα καθοδηγούν και επιταχύνουν κάθε στάδιο της διαδικασίας.

Μια πρώτη κατεύθυνση αφορά τη γενικευμένη χρήση της τεχνητής νοημοσύνης στην αποκωδικοποίηση του DNA. Πρόσφατες συστηματικές ανασκοπήσεις καταγράφουν πώς μέθοδοι μηχανικής και βαθιάς μάθησης εφαρμόζονται πλέον όχι μόνο στην ανάλυση, αλλά και στη βελτίωση της ποιότητας των αναγνώσεων, στη διόρθωση σφαλμάτων και στην ερμηνεία των αποτελεσμάτων, επισημαίνοντας ταυτόχρονα τις προκλήσεις και τις ανοιχτές κατευθύνσεις του πεδίου [2]. Παράλληλα εμφανίζεται η άνοδος των γενετικών (generative) μοντέλων στη βιοπληροφορική, τα οποία δεν περιορίζονται στην ταξινόμηση ή την πρόβλεψη, αλλά είναι ικανά να παράγουν νέες αλληλουχίες, να συμπληρώνουν ελλιπή δεδομένα και να προσομοιώνουν βιολογικά μοτίβα [8]. Η μετάβαση αυτή από την ανάλυση προς την "παγωγή" αντικατοπτρίζει την ίδια πορεία που ακολούθησαν τα γλωσσικά μοντέλα στην επεξεργασία φυσικής γλώσσας, και θεωρείται από τις πιο υποσχόμενες εξελίξεις. Η ίδια τάση επιβεβαιώνεται και από κριτικές ανασκοπήσεις της υπολογιστικής νοημοσύνης στην ανάλυση αλληλουχιών DNA, οι οποίες συγκλίνουν στο συμπέρασμα ότι τα μοντέλα βαθιάς μάθησης, και ιδίως τα γλωσσικά μοντέλα, κυριαρχούν πλέον στην πλειονότητα των εργασιών [9].

Μια δεύτερη, ιδιαίτερα κρίσιμη κατεύθυνση είναι η εφαρμογή αυτής της εξέλιξης των μοντέλων τεχνητής νοημοσύνης στη δημόσια υγεία. Ο συνδυασμός ανάγνωσης και αναζήτησης σε βάσεις δεδομένων, με τεχνητή νοημοσύνη, αξιοποιείται ήδη στην αντιμετώπιση της ανθεκτικότητας των παθογόνων μικροοργανισμών, ενός από τα σοβαρότερα σύγχρονα προβλήματα υγείας. Συγκεκριμένα μοντέλα εκπαιδευμένα σε δεδομένα γονιδιωμάτων μπορούν να προβλέψουν ποια στελέχη παθογόνων είναι ανθεκτικά σε συγκεκριμένα αντιβιοτικά, επιταχύνοντας την κλινική απόφαση [14]. Το παράδειγμα αυτό είναι χαρακτηριστικό του πώς η τεχνολογική σύγκλιση μεταφράζεται σε άμεσο κοινωνικό όφελος, συνδέοντας τους τέσσερις άξονες της παρούσας εργασίας, αποθήκευση, αναζήτηση, αξιοποίηση και ανάλυση, σε μια ενιαία εφαρμοσμένη ροή.

Τέλος, η πρόοδος δεν συντελείται μόνο σε πλάτος αλλά και σε βάθος. Πέρα από τις γενικές τάσεις, εντατική έρευνα διεξάγεται και σε επιμέρους εξειδικευμένες εργασίες. Χαρακτηριστικό παράδειγμα αποτελεί η πρόβλεψη σημείων έναρξης αντιγραφής, όπου μια πρόσφατη συγκριτική ανασκόπηση καταγράφει τη σταδιακή μετάβαση από τις κλασικές ευρετικές μεθόδους στις σύγχρονες τεχνικές βαθιάς μάθησης [6]. Η ταυτόχρονη αυτή πρό-

οδος, σε πλάτος και σε βάθος, υποδηλώνει ότι η ενσωμάτωση της τεχνητής νοημοσύνης στη βιοπληροφορική βρίσκεται ακόμη σε ανοδική τροχιά, με πολλά περιθώρια εξέλιξης.

Κεφάλαιο 7

Επίλογος

Η εκθετική αύξηση των δημόσιων βιολογικών δεδομένων, όπως αναλύθηκε εκτενώς στα προηγούμενα κεφάλαια, έχει μεταμορφώσει τη βιοπληροφορική σε ένα πεδίο όπου η διαχείριση της πληροφορίας είναι εξίσου κρίσιμη με την παραγωγή της. Η παρούσα εργασία επιχείρησε να χαρτογραφήσει αυτή την πραγματικότητα, ακολουθώντας τον κύκλο ζωής των δεδομένων μέσα από τέσσερις συμπληρωματικές μελέτες.

Ξεκινώντας από την αποθήκευση και διάθεση των δεδομένων, είδαμε πώς αποθετήρια όπως το GenBank, μέσα στο ευρύτερο οικοσύστημα του INSDC, συγκεντρώνουν, οργανώνουν και διαθέτουν παγκοσμίως έναν τεράστιο όγκο αλληλουχιών, θέτοντας ταυτόχρονα τις βάσεις για την ποιότητα και τη διαλειτουργικότητα που απαιτούν όλα τα επόμενα στάδια. Στη συνέχεια, το ζήτημα της αναζήτησης ανέδειξε μια θεμελιώδη πρόκληση, η οποία αφορά το πώς καθίσταται αναζητήσιμος ένας όγκος δεδομένων κλίμακας petabase. Το MetaGraph έδειξε ότι κάτι που θα θεωρούνταν αδύνατο πριν λίγα χρόνια (η αναζήτηση με βάση την αλληλουχία σε ολόκληρα δημόσια αρχεία), είναι πλέον εφικτό και, το σημαντικότερο, οικονομικά προσιτό.

Το τρίτο σκέλος, εκείνο της αξιοποίησης των δεδομένων, ανέδειξε πώς ακόμη και δεδομένα που συλλέχθηκαν για διαφορετικό σκοπό "οι εκτός στόχου αναγνώσεις" μπορούν να επαναχρησιμοποιηθούν για την ανακάλυψη νέων παθογόνων και τη μελέτη οικολογικών σχέσεων, χωρίς την παραγωγή νέων δεδομένων. Τέλος, το σκέλος της ανάλυσης των δεδομένων έδειξε πώς μέθοδοι τεχνητής νοημοσύνης όπως τα word embeddings και llm's μεταφέρουν στη βιολογία τεχνικές που αντιμετωπίζουν τις αλληλουχίες ως μια ιδιότυπη "γλώσσα", ανοίγοντας νέους δρόμους στην ερμηνεία του γενετικού υλικού.

Παρά τη διαφορετική προέλευση των τεσσάρων έργων, αναδείχθηκε ένας κοινό θεματικό πλαίσιο. Οι ίδιες θεμελιώδεις έννοιες, παραδείγματος χάρη το *k-mer* ως στοιχειώδης μονάδα, οι αρχές FAIR, η κοινή υποδομή του INSDC, επανέρχονται σε κάθε κεφάλαιο, φανερώνοντας ότι τα τέσσερα ζητήματα δεν είναι ανεξάρτητα αλλά κρίκοι μιας ενιαίας αλυσίδας. Πιο αναλυτικά η ποιότητα της αποθήκευσης καθορίζει την αποτελεσματικότητα της αναζήτησης, η οποία με τη σειρά της τροφοδοτεί την αξιοποίηση και, τελικά, την ανάλυση.

Οι μελλοντικές κατευθύνσεις που παρουσιάστηκαν όπως η επέκταση των εκτός στόχου

αναγνώσεων σε νέα πεδία, τα δυναμικά και ανθεκτικά ευρετήρια, και κυρίως η σύγκλιση της τεχνητής νοημοσύνης με την αλληλουχία των δεδομένων δείχνουν ένα πεδίο που βρίσκεται ακόμη σε πλήρη ανάπτυξη. Η κοινή συνισταμένη όλων παραμένει η ανάγκη τα δημόσια δεδομένα να γίνουν όχι απλώς μεγαλύτερα, αλλά πραγματικά αξιοποιήσιμα, εύκολα εντοπίσιμα, αξιόπιστα και ανοιχτά προς επαναχρησιμοποίηση. Καθώς η βιολογία εισέρχεται οριστικά στην εποχή των δεδομένων μεγάλης κλίμακας, η ικανότητά μας να τα αποθηκεύουμε, να τα αναζητούμε, να τα αξιοποιούμε και να τα αναλύουμε αποδοτικά θα καθορίσει, σε μεγάλο βαθμό, τον ρυθμό των επόμενων επιστημονικών ανακαλύψεων.

Βιβλιογραφία

- [1] Asim, M.N., Ibrahim, M.A., Zaib, A., & Dengel, A. (2025). DNA sequence analysis landscape: a comprehensive review of DNA sequence analysis task types, databases, datasets, word embedding methods, and language models. *Frontiers in Medicine*, 12, 1503229. <https://doi.org/10.3389/fmed.2025.1503229>
- [2] Athanasopoulou, K., Michalopoulou, V.-I., Scorilas, A., & Adamopoulos, P.G. (2025). Integrating artificial intelligence in next-generation sequencing: advances, challenges, and future directions. *Current Issues in Molecular Biology*, 47(6), 470. <https://doi.org/10.3390/cimb47060470>
- [3] Danielewski, M., Szalata, M., Nowak, J.K., Walkowiak, J., Słomski, R., & Wielgus, K. (2025). History of biological databases, their importance, and existence in modern scientific and policy context. *Genes*, 16(1), 100. <https://doi.org/10.3390/genes16010100>
- [4] Domingues, I., & Santos, J.A.M. (2026). Bioinformatics tools, databases, and data formats: a functional overview for introductory sequence-based and NGS workflows. *Applied Sciences*, 16(13), 6666. <https://doi.org/10.3390/app16136666>
- [5] Heather, J.M., & Chain, B. (2016). The sequence of sequencers: the history of sequencing DNA. *Genomics*, 107(1), 1–8. <https://doi.org/10.1016/j.ygeno.2015.11.003>
- [6] Jomaa, H., & Assaf, R. (2026). Computational prediction of replication origins: a comparative review of methods, benchmarks, and trends from heuristics to deep learning. *Briefings in Bioinformatics*, 27, bbag315. <https://doi.org/10.1093/bib/bbag315>
- [7] Karasikov, M., Mustafa, H., Danciu, D., Kulkov, O., Zimmermann, M., Barber, C., Räscht, G., & Kahles, A. (2025). Efficient and accurate search in petabase-scale sequence repositories. *Nature*, 647, 1036–1044. <https://doi.org/10.1038/s41586-025-09603-w>
- [8] Karim, W., Alvi, R., Zaman, S.B., Abian, A.I., Raiaan, M.A.K., Mukta, S., Rashid, M.R.U., Islam, M.R., & Sebastian, Y. (2026). Generative artificial intelligence in

- bioinformatics: a systematic review of models, applications, and methodological advances. *Archives of Computational Methods in Engineering*. <https://doi.org/10.1007/s11831-026-10743-z>
- [9] Mathur, G., Pathik, N., & Pathekar, P. (2026). Computational intelligence in DNA sequence analysis: a critical review. In *2026 IEEE 1st International Conference on Intelligent Technologies for a Sustainable and Inclusive Future (ICITSIF)*. IEEE. <https://doi.org/10.1109/ICITSIF69060.2026.11608602>
 - [10] Morales Garcia, M. (2026). Selection inference in the complex genomic landscape of the spruce bark beetle and the off-target detection of associated organisms. *Doctoral dissertation*, Jagiellonian University (ruj.uj.edu.pl).
 - [11] Richard, D., & Poulicard, N. (2025). Data mining of public genomic repositories: harnessing off-target reads to expand microbial pathogen genomic resources. *arXiv preprint*, arXiv:2505.10017.
 - [12] Saini, D. (2026). *Gene regulation by DNA methylation during mammalian embryonic development* (Doctoral dissertation). Department of Biochemistry, McGill University.
 - [13] Sayers, E.W., Cavanaugh, M., Frisse, L., Pruitt, K.D., Schneider, V.A., Underwood, B.A., Yankie, L., & Karsch-Mizrachi, I. (2025). GenBank 2025 update. *Nucleic Acids Research*, 53(D1), D56–D61. <https://doi.org/10.1093/nar/gkae1114>
 - [14] Scaglione, G., Mastroianni, N., Rizzo, A., Palomba, E., Carcione, D., Rimoldi, S.G., Brigante, G., Principe, L., Borgonovo, F., et al. (2026). Integrating artificial intelligence with genome sequencing against antimicrobial resistance: a narrative review. *Frontiers in Public Health*, 14, 1757161. <https://doi.org/10.3389/fpubh.2026.1757161>
 - [15] Seiler, E., Willemsen, M., Piro, V.C., & Reinert, K. (2026). Dynamic hierarchical interleaved Bloom filter: an updatable index for large-scale fast sequence search. *bioRxiv* (preprint, not peer-reviewed). <https://doi.org/10.64898/2026.08.26.747224>
 - [16] Small, H. (2023). Bayesian history of science: the case of Watson and Crick and the structure of DNA. *Quantitative Science Studies*, 4(1), 209–228. https://doi.org/10.1162/qss_a_00233
 - [17] Synk, R.P., Pandey, P., Sahinalp, S.C., & Duraiswami, R. (2026). LOCALE: local-alignment embeddings for noise-robust DNA search at SRA scale. *bioRxiv* (preprint, not peer-reviewed). <https://doi.org/10.64898/2026.05.12.724581>

- [18] Vogt, H.B. (2025). Discovery of DNA. *South Dakota Medicine*, 78(12), 536.
- [19] Vu, N.T., Shen, X., Gibson-Kueh, S., Carrai, M., Terence, C., Poon, Z.W.J., Nelson, S.P., Senapin, S., Dong, H.T., Loh, J.-Y., Jerry, D.R., & Domingos, J.A. (2026). Microbiome and pathobiome characterization in farmed barramundi (*Lates calcarifer*) during and post scale drop disease outbreaks. *Journal of Fish Diseases*. <https://doi.org/10.1111/jfd.70225>
- [20] Watson, J.D., & Crick, F.H.C. (1953). Molecular structure of nucleic acids: a structure for deoxyribose nucleic acid. *Nature*, 171(4356), 737–738.
- [21] Witkowski, J., & Stillman, B. (2026). James D. Watson (1928–2025): influencer of science and society. *Proceedings of the National Academy of Sciences*, 123(7), e2600779123. <https://doi.org/10.1073/pnas.2600779123>